

UNIVERSITAT POLITÈCNICA DE VALÈNCIA

etsinf

Escola Tècnica Superior d'Enginyeria Informàtica

Escuela Técnica Superior de Ingeniería Informática
Universidad Politécnica de Valencia

De señal acústica a partitura: transcripción automática de piano mediante aprendizaje profundo

TRABAJO FIN DE GRADO

Grado en Ingeniería Informática

Autor: Jorge Rodríguez González

Tutor: Alfons Juan Císcar

Curso 2025-2026

Resum

La transcripció automàtica de música (AMT) constitueix un dels problemes centrals de la recuperació d'informació musical (MIR), l'objectiu de la qual és convertir un senyal d'àudio en una representació simbòlica de la música interpretada. En el cas del piano, l'objectiu és obtindre a partir de l'àudio una representació MIDI que capture amb precisió els esdeveniments de nota –to, inici, final i dinàmica– presents en la interpretació. Aquest treball aborda la replicació i l'avaluació de dos sistemes de l'estat de l'art per a la transcripció automàtica. En primer lloc, s'entrena un model MFT-FiLM (*Multitask Frequency-Time Feature-wise Linear Modulation*) que combina convolucions espectrals i xarxes recurrents bidireccionals per a l'estimació conjunta d'*onsets*, *offsets*, *frames* i velocitats. A continuació, s'entrena un model Transkun, un sistema basat en *transformers* que aborda la transcripció com un problema de traducció de seqüències. Tots dos models s'avaluen de forma quantitativa sobre el conjunt de test de MAESTRO seguint el protocol estàndard (`mir_eval`). Addicionalment, s'avalua la capacitat de generalització de tots dos models sobre el *dataset* PiJAMA, la distribució de repertori i àudio del qual difereix de MAESTRO, i s'exploren modificacions experimentals orientades a la millora del rendiment dels models.

Paraules clau: Transcripció automàtica, xarxes convolucionals, *transformers*, *onset*, *offset*, *frame*, modulació lineal, MIDI, espectrograma, MAESTRO, PiJAMA, piano

Resumen

La transcripción automática de música (AMT) constituye uno de los problemas centrales de la recuperación de información musical (MIR), cuyo objetivo es convertir una señal de audio en una representación simbólica de la música interpretada. En el caso del piano, el objetivo es obtener a partir del audio una representación MIDI que capture con precisión los eventos de nota –tono, inicio, final y dinámica– presentes en la interpretación. Este trabajo aborda la replicación y evaluación de dos sistemas del estado del arte para la transcripción automática. En primer lugar, se entrena un modelo MFT-FiLM (*Multitask Frequency-Time Feature-wise Linear Modulation*) que combina convoluciones espectrales y redes recurrentes bidireccionales para la estimación conjunta de *onsets*, *offsets*, *frames* y velocidades. A continuación, se entrena un modelo Transkun, un sistema basado en transformers que aborda la transcripción como un problema de traducción de secuencias. Ambos modelos se evalúan de forma cuantitativa sobre el conjunto de test de MAESTRO siguiendo el protocolo estándar (`mir_eval`). Adicionalmente se evalúa la capacidad de generalización de ambos modelos sobre el *dataset* PiJAMA, cuya distribución de repertorio y audio difiere de MAESTRO, y se exploran modificaciones experimentales orientadas a la mejora del rendimiento de los modelos.

Palabras clave: Transcripción automática, redes convolucionales, *transformers*, *onset*, *offset*, *frame*, modulación lineal, MIDI, espectrograma, MAESTRO, PiJAMA, piano

Abstract

Automatic Music Transcription (AMT) constitutes one of the core problems in Music Information Retrieval (MIR), aiming to convert an audio signal into a symbolic representation of the performed music. In the case of the piano, the goal is to obtain a MIDI representation from the audio that accurately captures the note events –pitch, onset, offset, and dynamics– present in the performance. This work addresses the replication and evaluation of two state-of-the-art systems for automatic transcription. First, an MFT-FiLM

(Multitask Frequency-Time Feature-wise Linear Modulation) model is trained, which combines spectral convolutions and bidirectional recurrent networks for the joint estimation of onsets, offsets, frames, and velocities. Next, a Transkun model is trained, a *transformer*-based system that approaches transcription as a sequence translation problem. Both models are quantitatively evaluated on the MAESTRO test set following the standard protocol (`mir_eval`). Additionally, the generalization capability of both models is evaluated on the PiJAMA *dataset*, whose repertoire and audio distribution differs from MAESTRO, and experimental modifications aimed at improving the models' performance are explored.

Key words: Automatic transcription, convolutional networks, *transformers*, *onset*, *offset*, *frame*, linear modulation, MIDI, spectrogram, MAESTRO, PiJAMA, piano

Índice general

Índice general v
Índice de figuras vii
Índice de tablas vii

Lista de Acrónimos ix
1 Introducción 1
1.1 Motivación . . . 1
1.2 Objetivos . . . 1
1.3 Estructura de la memoria . . . 1
2 Preliminares 3
2.1 ?? ???? ???? ? ?? ?? . . . 3
3 MAESTRO 5
3.1 Introducción . . . 5
3.2 Origen de los datos . . . 5
3.3 Adquisición y anotación . . . 7
3.4 Características del *dataset* . . . 7
3.5 Evolución del *dataset* . . . 9
3.6 Distribución y licencia . . . 9
3.7 Limitaciones . . . 9
3.8 Relevancia para este trabajo . . . 10
3.9 Evaluación estándar . . . 10
4 MFT-FiLM 13
4.1 Introducción . . . 13
4.2 Transformada Q Constante . . . 13
4.3 Arquitectura general . . . 16
4.4 Módulos FiLM, FT-FiLM e IFT-FiLM . . . 17
4.5 Función de pérdida y eficiencia . . . 20
4.6 Experimentos . . . 21
4.7 Conclusiones . . . 27
5 Transkun 29
5.1 Introducción . . . 29
5.2 Arquitectura general . . . 29
5.3 Espectrograma de entrada, submuestreo y *event tracks* . . . 30
5.4 Transformer encoder no jerárquico . . . 32
5.5 Scoring por producto interior y semi-CRF . . . 34
5.6 Predicción de atributos y procesado por segmentos . . . 36
5.7 Configuración del experimento . . . 38
5.8 Preproceso y entrenamiento . . . 38
5.9 Resultados . . . 38
6 Conclusiones 39
Bibliografía 41

Apéndice

A Configuración del experimento MFT-FiLM **45**
A.1 Entorno de ejecución y dependencias 45
A.2 Rendimiento del entrenamiento en el clúster 46
A.3 Parámetros de configuración del experimento 46
A.4 Herramientas de preprocesamiento de audio y MIDI 47

Índice de figuras

3.1 Sistema de sensores de un Yamaha Disklavier 6

4.1 Comparación de representaciones tiempo–frecuencia 15
4.2 Esquema general del modelo MFT-FiLM 16
4.3 Arquitectura detallada de los módulos FT-FiLM e IFT-FiLM 18
4.4 Convergencia de la pérdida durante la primera época 23
4.5 Evolución de la pérdida de entrenamiento y validación por época 24
4.6 Evolución de la métrica F_1 en el conjunto de validación 25
4.7 Precisión y *recall* en el conjunto de validación 26

5.1 Esquema general del modelo Transkun 31
5.2 Bloques constitutivos del transformer encoder de Transkun 33

Índice de tablas

3.1 Top 20 compositores en MAESTRO V3.0.0 8
3.2 Estadísticas de MAESTRO V3.0.0 por partición 8
3.3 Evolución de MAESTRO entre las versiones V1, V2 y V3 9
3.4 Condiciones de aceptación de un evento predicho como verdadero positivo según la variante de métrica de nota empleada. 12

4.1 Resultados del F_1 de MFT-FiLM sobre MAESTRO v3.0.0 22
4.2 Resultados de la precisión de MFT-FiLM sobre MAESTRO v3.0.0 22
4.3 Resultados del *recall* de MFT-FiLM sobre MAESTRO v3.0.0 22

A.1 Parámetros de configuración establecidos en `constant_macro.py` para el entrenamiento de MFT-FiLM. 47

Lista de Acrónimos

AMT *Automatic Music Transcription* (Transcripción Automática de Música)

ASAP *Aligned Scores and Performances*

CC *Control Change* (mensaje de control MIDI)

CQT *Constant-Q Transform* (Transformada Q Constante)

CSV *Comma-Separated Values*

MEI *Music Encoding Initiative*

MusicXML *Music Extensible Markup Language*

FiLM *Feature-wise Linear Modulation* (Modulación Lineal por Características)

FG-LSTM *Frequency-Grouped Long Short-Term Memory*

FT-FiLM *Frequency-Time Feature-wise Linear Modulation*

IFT-FiLM *Inter-Task Frequency-Time Feature-wise Linear Modulation*

JSON *JavaScript Object Notation*

LSTM *Long Short-Term Memory*

MAESTRO *MIDI and Audio Edited for Synchronous Tracks and Organization*

MAPS *MIDI Aligned Piano Sounds*

MEI *Music Encoding Initiative*

MFT-FiLM *Multitask Frequency-Time Feature-wise Linear Modulation*

MIDI *Musical Instrument Digital Interface*

MIR *Music Information Retrieval* (Recuperación de Información Musical)

MTL *Multitask Learning* (Aprendizaje Multitarea)

PCM *Pulse Code Modulation* (Modulación por Impulsos Codificados)

PiJAMA *Piano Jazz and More Audio*

SLURM *Simple Linux Utility for Resource Management*

STFT *Short-Time Fourier Transform* (Transformada de Fourier de Tiempo Corto)

VRAM *Video Random Access Memory*

WAV *Waveform Audio File Format*

BCE *Binary Cross-Entropy* (Entropía Cruzada Binaria)

CCE *Categorical Cross-Entropy* (Entropía Cruzada Categórica)

MAC *Multiply–Accumulate* (Operación de Multiplicación-Accumulación)

ReLU *Rectified Linear Unit*

GELU *Gaussian Error Linear Unit*

SGD *Stochastic Gradient Descent* (Descenso de Gradiente Estocástico)

ECC *Error-Correcting Code*

HPC *High-Performance Computing* (Cómputo de Altas Prestaciones)

CAPÍTULO 1
Introducción

????? ????????????? ????????????? ????????????? ????????????? ?????????????

1.1 Motivación

????? ????????????? ????????????? ????????????? ????????????? ?????????????

1.2 Objetivos

????? ????????????? ????????????? ????????????? ????????????? ?????????????

1.3 Estructura de la memoria

????? ????????????? ????????????? ????????????? ????????????? ?????????????

CAPÍTULO 2
Preliminares

????? ????????????? ????????????? ????????????? ????????????? ?????????????

2.1 ?? ???? ???? ? ?? ??

????? ????????????? ????????????? ????????????? ????????????? ?????????????

CAPÍTULO 3
MAESTRO

3.1 Introducción

Uno de los principales factores que limitan el rendimiento de los sistemas de AMT basados en el aprendizaje profundo es la disponibilidad de datos de entrenamiento etiquetados con alta precisión y en cantidad suficiente para que los modelos sean capaces de generalizar. Hasta 2018, los *datasets* disponibles para esta tarea, como **MAPS** (*MIDI Aligned Piano Sounds*), no superaban las 70 horas de audio, lo que suponía una barrera significativa para el entrenamiento de nuevos modelos [1].

En el ámbito de este trabajo, **Google Magenta** publicó el *dataset* **MAESTRO** [6] (*Midi and Audio Edited for Synchronous Tracks and Organization*), que supuso un cambio de paradigma al ofrecer casi 200 horas de grabaciones de piano de alta calidad con alineación precisa entre audio y etiquetas MIDI. La publicación de MAESTRO demostró inmediatamente su impacto: el modelo **Onsets and Frames**, entrenado sobre MAESTRO alcanzó un **F1 de 67,43 %** en la evaluación sobre grabaciones Disklavier del conjunto MAPS, superando notablemente el **50,22 %** obtenido por el mismo modelo entrenado sobre MAPS únicamente [5, 6]. Desde entonces, MAESTRO se ha consolidado como el estándar de facto para la evaluación y comparación de sistemas de transcripción automática de piano.

En este trabajo se utiliza la versión **V3.0.0** [3] del *dataset*, publicada en 2020, que constituye una versión más depurada y es actualmente la referencia en la comunidad investigadora.

Este capítulo analiza el *dataset* MAESTRO. La Sección 3.2 describe su origen en la *International Piano-e-Competition* y el uso de pianos Yamaha Disklavier. El proceso de adquisición y anotación se detalla en la Sección 3.3, mientras que sus características técnicas, evolución y licenciamiento se exponen en las Secciones 3.4, 3.5 y 3.6, respectivamente. Posteriormente, se discuten sus limitaciones (Sección 3.7) y su relevancia para este trabajo (Sección 3.8). Finalmente, la Sección 3.9 presenta el protocolo de evaluación estándar para la transcripción automática de piano.

3.2 Origen de los datos

Los datos que constituyen MAESTRO provienen de grabaciones recogidas durante diez ediciones de la *International Piano-e-Competition*, una competición de piano de nivel internacional celebrada anualmente en la que pianistas virtuosos interpretan sobre pianos de cola **Yamaha Disklavier** equipados con un sistema integrado de captura MIDI de alta precisión [3]. Esta competición es la fuente exclusiva de todas las grabaciones del

dataset, lo que dota al conjunto de datos de una coherencia excepcional en términos de calidad de la interpretación, condiciones acústicas y equipamiento.

En cuanto al instrumento empleado para la captación, el elemento técnico que garantiza la calidad de MAESTRO es el piano Yamaha Disklavier, un piano de cola acústico convencional al que se le ha añadido un sistema electrónico de captura que registra, con alta precisión temporal, el movimiento de cada tecla y pedal durante la interpretación [6]. Este sistema está formado por un conjunto de sensores situados bajo las teclas y pedales, que detectan la posición y velocidad de cada elemento, así como actuadores que permiten reproducir automáticamente la interpretación a partir de los datos MIDI [4]. A diferencia de los sintetizadores o controladores MIDI, el Disklavier produce sonido acústico real al mismo tiempo que genera los datos MIDI, lo que garantiza que el audio captado por los micrófonos y el MIDI registrado sean inherentemente sincrónicos [6].

La Figura 3.1 ilustra la disposición de estos componentes bajo el teclado. La clave tecnológica que aporta valor a este *dataset* reside en el uso de **sensores ópticos sin contacto**. Al evitar cualquier fricción o resistencia mecánica adicional, el sistema logra escanear continuamente el movimiento del martillo y la tecla para medir la dinámica (velocidad) y los instantes de *onset* y *offset* con absoluta fidelidad, todo ello preservando intacta la experiencia táctil del intérprete [4].



Figura 3.1: Sistema de sensores de un Yamaha Disklavier. En la parte superior se aprecia el teclado con sus teclas blancas y negras. En la franja central, bajo cada tecla, se dispone una fila de **sensores ópticos** cuyos emisores de luz infrarroja (visibles como puntos rojos) detectan de forma continua y sin contacto el desplazamiento del martillo y de la tecla a lo largo de su recorrido. A ambos lados se observan los mecanismos de acción con sus amortiguadores y pines de guía. Al no introducir ninguna fricción ni resistencia mecánica adicional, estos sensores pueden medir con precisión el instante exacto en que cada tecla es pulsada (*onset*) y liberada (*offset*), así como la velocidad de pulsación, que determina la dinámica (intensidad) de la nota en el protocolo MIDI. Esta arquitectura de medición sin contacto es la que permite que el *dataset* MAESTRO ofrezca una alineación entre el audio grabado y las etiquetas MIDI de aproximadamente ± 3 ms, muy por debajo del umbral de percepción temporal humano [4].

La alineación resultante entre la señal de audio y las etiquetas MIDI en MAESTRO es de aproximadamente ± 3 ms, muy inferior al umbral de percepción temporal humano (estimado en 20 ms), lo que hace que las etiquetas se consideren alineadas a nivel de fonación. Esta precisión es fundamental para entrenar modelos de transcripción: cualquier desalineación sistemática entre el onset de una nota en el audio y su etiqueta MIDI correspondiente introduce ruido en los gradientes durante el entrenamiento y degrada el rendimiento de los modelos.

3.3 Adquisición y anotación

En primer lugar, el audio se graba en calidad CD o superior, con una frecuencia de muestreo de 44,1 a 48 kHz y una profundidad de bit de 16 bits PCM[1] estéreo. Esta calidad es suficiente para representar con fidelidad toda la gama de frecuencias audibles relevantes para el piano (entre 28 Hz y 4 kHz aproximadamente para los fundamentales, con armónicos que se extienden hasta 16-20 kHz). Las grabaciones se almacenan sin compresión con pérdida, lo que preserva toda la información espectral original.

De forma simultánea a la captura del audio, el sistema MIDI del Disklavier captura automáticamente los siguientes eventos para cada interpretación:

- Velocidades de pulsación de teclas (*key strike velocities*, canal MIDI, nota, velocidad 0-127): codifican la dinámica de cada nota individual.
- Posición del pedal *sustain* (Control Change CC64): el pedal más utilizado en el piano, que prolonga el sonido de una tecla.
- Posición del pedal *sostenuto* (Control Change CC66): permite mantener seleccionadas únicamente las notas que están sonando en el momento de su activación.
- Posición del pedal *una corda* (Control Change CC67): pedal izquierdo, que reduce el volumen y modifica el timbre.

La inclusión de los tres pedales hace a MAESTRO uno de los pocos *datasets* de transcripción de piano con **anotación de pedal completa**, lo que resulta especialmente relevante para sistemas que aspiran a una transcripción expresiva o a la síntesis de audio realista a partir de MIDI.

Cada grabación se segmenta automáticamente en piezas musicales individuales y se anota con los siguientes metadatos:

- Compositor canónico (nombre normalizado).
- Título de la obra.
- Año de la grabación.
- Partición sugerida (train/validation/test).

Estos metadatos permiten analizar el repertorio, controlar posibles solapamientos entre particiones y reproducir de forma precisa los protocolos de evaluación propuestos por los autores [3].

3.4 Características del *dataset*

MAESTRO V3.0.0 está formado por un total de 1 276 grabaciones de interpretaciones de piano, que suman 198,7 horas de audio y más de 7,4 millones de eventos MIDI [3]. El repertorio incluye obras de 60 compositores distintos que se asocian principalmente a la música clásica occidental entre los siglos XVII y XX.

[1] PCM (*Pulse Code Modulation*) es una técnica de representación digital de señales analógicas basada en el muestreo y la cuantización, ampliamente utilizada en sistemas de audio sin compresión.

Compositor	Grabaciones	Obras únicas	Duración (h)
Frédéric Chopin	201	107	26,22
Franz Schubert	186	96	35,82
Ludwig van Beethoven	146	95	26,92
Johann Sebastian Bach	145	93	13,77
Franz Liszt	131	91	20,27
Sergei Rachmaninoff	59	50	6,66
Robert Schumann	49	31	15,72
Claude Debussy	45	41	5,97
Joseph Haydn	40	29	4,72
Wolfgang Amadeus Mozart	38	35	5,60
Alexander Scriabin	35	26	5,35
Domenico Scarlatti	31	29	1,71
Felix Mendelssohn	28	8	4,85
Johannes Brahms	26	23	8,06
Franz Schubert / Franz Liszt	10	7	0,69
Isaac Albéniz	7	6	0,87
Modest Mussorgsky	6	2	3,17
Pyotr Ilyich Tchaikovsky / Mikhail Pletnev	6	6	0,80
Pyotr Ilyich Tchaikovsky	6	6	0,71
Muzio Clementi	6	6	0,87

Tabla 3.1: Los 20 compositores con mayor número de grabaciones en MAESTRO V3.0.0 [3].

La Tabla 3.1 muestra la distribución típica de competiciones internacionales de piano, que tienden a centrarse en el período Romántico y en los grandes compositores del clasicismo tardío.

Respecto a las particiones, estas están predefinidas y publicadas con el *dataset*, lo que garantiza la reproducibilidad de los experimentos y permite la comparación directa de distintos modelos. Esto es fundamental en un campo como AMT, en el que pequeñas diferencias en la partición de datos pueden producir variaciones significativas en los resultados reportados. En la Tabla 3.2 se detallan las estadísticas principales por partición.

Partición	Grabaciones	Duración (h)	Tamaño (GB)	Notas (M)
Train	962	159,2	96,3	5,66
Validation	137	19,4	11,8	0,64
Test	177	20,0	12,1	0,74
Total	**1,276**	**198,7**	**120,2**	**7,40**

Tabla 3.2: Estadísticas de MAESTRO V3.0.0 desglosadas por partición.

La política de particionado distingue el *dataset* de otras colecciones de audio-MIDI. El criterio establecido por los autores es el siguiente: una misma composición no puede aparecer simultáneamente en más de una partición, aunque haya sido interpretada por distintos pianistas en periodos diferentes [3].

Esta decisión de diseño es crucial para garantizar la validez de los experimentos. Si múltiples interpretaciones de una misma obra aparecieran en entrenamiento y test, un modelo podría aprender características tímbricas o estructurales específicas de esa obra y obtener resultados artificialmente buenos en la evaluación sin haber generalizado correctamente. De esta forma, los modelos se evalúan sobre obras no vistas en entrenamiento, lo que constituye una medida mucho más exigente y realista de rendimiento.

3.5 Evolución del *dataset*

MAESTRO ya va por su tercera versión desde su publicación original en 2018. En la Tabla 3.3 podemos ver características y principales cambios de cada versión.

Versión	Año	Grabaciones	Horas	Notas (M)	Principal novedad
V1.0.0	2018	1,184	172,3	6,18	Publicación original [3]; datos 2004–2016.
V2.0.0	2019	1,282	201,2	7,13	Añade edición 2018 [3]; incorpora pedales *sostenuto* y *una corda*.
V3.0.0	2020	1,276	198,7	7,04	Elimina 6 grabaciones con acompañamiento orquestal [3].

Tabla 3.3: Comparativa de las tres versiones publicadas de MAESTRO.

La transición de V2.0.0 a V3.0.0 merece especial atención. Contrariamente a lo que podría esperarse, la versión más reciente no amplía el *dataset*, sino que realiza una corrección de calidad eliminando 6 grabaciones que no eran de piano solo. La presencia de estas grabaciones en versiones anteriores constituía una inconsistencia que podía afectar negativamente al entrenamiento de modelos especializados en piano solo. Esta corrección hace que las particiones de V3.0.0 no sean compatibles con las de V2.0.0, por lo que todos los experimentos de este trabajo se realizan íntegramente sobre V3.0.0 para garantizar la comparabilidad con los resultados publicados recientemente.

3.6 Distribución y licencia

MAESTRO se distribuye a través de Google Magenta en tres modalidades de descarga [3]:

- **Audio + MIDI** (120,2 GB sin comprimir): contiene los archivos WAV y MIDI completos, junto con los metadatos en formato CSV y JSON.
- **Solo MIDI** ($\sim$ 57 MB): para tareas que no necesiten el audio.
- **Comprimido con pérdida** (MP3/FLAC): versión reducida para almacenamiento limitado.

El *dataset* se distribuye con licencia *Creative Commons Attribution Non-Commercial Share Alike 4.0 International* (CC BY-NC-SA 4.0), que implica:

- Atribución obligatoria: cualquier uso debe citar la fuente original.
- Prohibido su uso con fines comerciales.
- Las obras derivadas deben distribuirse bajo la misma licencia.

Esta licencia es compatible con el uso académico en el contexto de un Trabajo de Fin de Grado.

3.7 Limitaciones

A pesar de sus fortalezas, MAESTRO presenta una serie de limitaciones que debemos tener en cuenta al interpretar los resultados de los sistemas entrenados sobre él.

Sesgo de repertorio. El repertorio es casi exclusivamente música clásica occidental de los siglos XVII-XX. Los modelos entrenados con MAESTRO no generalizan bien a géneros como el jazz, el pop o la música contemporánea con técnicas extendidas. Esto se debe a que las distribuciones de patrones armónicos, rítmicos y de velocidad son muy diferentes a las de la música clásica.

Sesgo de instrumento. Todas las grabaciones se realizaron sobre pianos Yamaha Disklavier del mismo modelo y en condiciones acústicas muy similares. Es por esto que los modelos entrenados con MAESTRO muestran una degradación significativa de rendimiento cuando se evalúan sobre grabaciones de pianos distintos en entornos con reverberación variable. Esto es especialmente relevante para aplicaciones del mundo real, donde el instrumento y la acústica son variables.

Ausencia de anotación de partitura. MAESTRO proporciona MIDI, pero no partitura en formato estándar como MusicXML o MEI [3]. Para tareas de transcripción audio-a-partitura (*Audio-to-Score*), como parte del flujo de las tareas de AMT, es necesario complementar MAESTRO con *datasets* que incluyan partituras anotadas, como ASAP (*Aligned Scores and Performances*).

3.8 Relevancia para este trabajo

MAESTRO V3.0.0 es el *dataset* principal empleado para el entrenamiento y evaluación de los modelos de transcripción automática de piano desarrollados en este trabajo.

Los modelos de referencia del estado del arte, incluyendo los modelos empleados en este trabajo, reportan sus resultados sobre las particiones fijas de MAESTRO, lo que hace directamente comparables los experimentos aquí presentados con los resultados publicados en la literatura.

Su volumen de casi 200 horas con más de **7 millones de eventos MIDI** proporciona datos suficientes para el entrenamiento de arquitecturas basadas en *transformers* sin riesgo de sobreajuste, siempre y cuando se apliquen las técnicas de regularización adecuadas. Todos estos eventos tienen una precisión de alineación de ± 3 ms, garantizando la calidad de las etiquetas *onset*, *offset* y velocidad, que son las variables objetivo de los modelos de transcripción empleados.

Finalmente, las particiones fijas y predefinidas garantizan la reproducibilidad de los experimentos.

3.9 Evaluación estándar

La evaluación cuantitativa de los sistemas de transcripción automática de piano entrenados sobre MAESTRO sigue un protocolo consolidado en la comunidad, implementado mediante la librería `mir_eval` [7]. Este protocolo es el empleado de forma invariante por todos los modelos del estado del arte que reportan resultados sobre este *dataset*, incluyendo los modelos reproducidos en este trabajo, MFT-FiLM y Transkun. Es por esto que en esta sección veremos cómo se evalúan ambos modelos.

Antes de aplicar las métricas, la salida de cada modelo, ya sea en forma de *piano roll* (MFT-FiLM) o en forma de intervalos decodificados (Transkun) se convierte en un conjunto de eventos MIDI discretos de la forma $\{(\text{tono}, t_{\text{onset}}, t_{\text{offset}}, v)\}$, donde el tono es un valor entero en $[21, 108]$ (las 88 teclas del piano estándar), los tiempos se expresan en segundos y la velocidad $v \in [0, 127]$ es un entero MIDI. La evaluación opera directamente sobre estos eventos discretos extraídos del MIDI de salida, comparándolos con

los eventos del MIDI de *ground truth*, sin acceder en ningún momento a la representación interna del modelo, de forma que se garantiza la independencia de las métricas respecto a la arquitectura empleada.

Las métricas previamente mencionadas se organizan en dos categorías en función del nivel de abstracción al que operan: nivel de trama y nivel de nota.

Las **métricas a nivel de trama** (*frame-level*) cuantifican la capacidad del modelo para estimar qué teclas están activas en cada instante temporal, con independencia de cómo se delimiten los eventos. Para ello, tanto la predicción como el *ground truth* se convierten en matrices binarias de dimensiones $T \times 88$, con resolución temporal infinitesimal (equivalente a un piano roll continuo), comparando el estado de activación de cada tecla en cada instante.

Se calculan la **precisión** (P), la **exhaustividad** (R, *Recall*) y la **puntuación** F_1:

$$P = \frac{VP}{VP + FP} \qquad R = \frac{VP}{VP + FN} \qquad F_1 = \frac{2 \cdot P \cdot R}{P + R} \tag{3.1}$$

donde VP son los verdaderos positivos (instantes y teclas correctamente activadas), FP los falsos positivos (activaciones predichas incorrectamente) y FN los falsos negativos (activaciones del *ground truth* no detectadas). Estas métricas de trama son las más directamente relacionadas con la audición subjetiva de la transcripción, ya que capturan el porcentaje de tiempo en que la armonía reconstruida es correcta. En términos musicales, una precisión alta indica que el modelo casi no introduce notas espurias que no aparecen en la grabación original, mientras que una exhaustividad alta implica que rara vez se olvida de activar notas que sí están presentes en la interpretación.

Por otro lado, las **métricas a nivel de nota** (*note-level*) operan sobre los eventos discretos y evalúan la capacidad del modelo para segmentar correctamente los límites temporales de las notas. Hay tres variantes de complejidad creciente:

- **Nota con *onset*** (*Note Onset*): una nota predicha se considera un verdadero positivo si y solo si su tono es correcto y su instante de inicio está dentro de una tolerancia de ± 50 ms respecto al *onset* de *ground truth* correspondiente.
- **Nota con *onset* y *offset*** (*Note w/ Offset*): además de las condiciones anteriores, el instante de finalización de la nota predicha debe encontrarse dentro de una tolerancia igual al máximo entre 50 ms y el 20 % de la duración de la nota de referencia. Esta condición menos restrictiva para el *offset* refleja la mayor dificultad de detección del final de una nota, especialmente en presencia de pedal de *sustain*, cuyo efecto prolonga la resonancia del instrumento más allá del instante de liberación de la tecla.
- **Nota con *onset*, *offset* y velocidad** (*Note w/ Offset & Velocity*): añade una condición sobre la estimación de la dinámica. La velocidad predicha debe satisfacer $|v_{\text{pred}} - v_{\text{ref}}| \leq 0{,}1$ tras escalar ambos valores al intervalo $[0, 1]$, lo que equivale a una tolerancia absoluta de aproximadamente 12,7 unidades MIDI. Esta es la métrica más exigente y la más representativa de la calidad de una transcripción completa de *performance* MIDI.

Desde la perspectiva de un intérprete, estas métricas de nota se aproximan mejor a la noción de "partitura correcta": no basta con que las notas suenen en algún momento, sino que deben empezar y terminar en puntos temporales razonables y con una intensidad coherente con la ejecución original.

Tabla 3.4: Condiciones de aceptación de un evento predicho como verdadero positivo según la variante de métrica de nota empleada.

Métrica	**Tono correcto**	**Tolerancia *onset***	**Condición adicional**
Frame	✓	—	—
Note Onset	✓	$\pm 50\,\text{ms}$	—
Note w/ Offset	✓	$\pm 50\,\text{ms}$	Tolerancia *offset*†
Note w/ Offset & Vel.	✓	$\pm 50\,\text{ms}$	Tolerancia *offset*† + $\lvert\Delta v\rvert \leq 0{,}1$

† máx(50 ms, 20 % de la duración de la nota)

La Tabla 3.4 resume las condiciones de aceptación de cada variante.

Todos los valores de las métricas se **promedian sobre el número de piezas** del conjunto de evaluación, en lugar de calcularse de forma global sobre todas las notas. Este criterio es adoptado de forma uniforme por todos los trabajos de referencia [5, 11, 16].

Los valores de F_1 son los indicadores principales de rendimiento en la literatura de AMT, siendo la ***Note Onset*** F_1 la métrica más citada para comparar modelos, y la ***Note w/ Offset & Velocity*** F_1 la más representativa de la calidad de la transcripción completa.

CAPÍTULO 4
MFT-FiLM

4.1 Introducción

La transcripción de música de piano polifónico mediante redes neuronales se aborda principalmente como un problema de detección multitarea (*Multitask Learning*, o MTL)[8, 5], en el que se estiman de forma conjunta el tono a nivel de *frame*, los *onsets*, *offsets* y la velocidad de las notas. Esta formulación permite explotar la fuerte correlación entre estos eventos para mejorar la precisión global del sistema, pero también pone de manifiesto las limitaciones de las arquitecturas multitarea clásicas, que pueden sufrir transferencia negativa o una fusión ineficaz de la información cuando las tareas comparten parámetros de manera demasiado rígida o combinan características sin un mecanismo de ponderación adecuado [11].

En este proyecto, la primera alternativa que se ha implementado es el modelo **MFT-FiLM** [11], que propone un enfoque más flexible y eficiente basado en el acondicionamiento mediante FiLM para fusionar dependencias espectrales y temporales, así como para intercambiar información entre las distintas ramas de tarea. El uso de módulos FT-FiLM e IFT-FiLM permite ajustar dinámicamente las representaciones intermedias en función del contexto, obteniendo un modelo con un número de parámetros reducido que mantiene un rendimiento competitivo en la transcripción de piano a partir de representaciones adaptadas a la percepción musical.

En este capítulo, la Sección 4.2 introduce la representación tiempo–frecuencia empleada, basada en la Transformada Q Constante (CQT). A continuación, la Sección 4.3 describe la arquitectura general del sistema y detalla los módulos FiLM, FT-FiLM e IFT-FiLM. La Sección 4.5 presenta la función de pérdida conjunta y analiza la eficiencia computacional del modelo. La Sección 4.6 recoge el preprocesamiento de los datos, el procedimiento de entrenamiento y los resultados alcanzados. Finalmente la Sección 4.7 sintetiza brevemente el trabajo realizado en este capítulo y destaca los principales resultados obtenidos.

4.2 Transformada Q Constante

El primer paso, antes de que la señal de audio entre en la red neuronal, es aplicar una cadena de preprocesamiento. El audio se convierte a mono y se remuestrea a 16 kHz. El oído humano no percibe las frecuencias de forma lineal: la diferencia perceptual entre 100 Hz y 200 Hz es la misma que entre 1000 Hz y 2000 Hz, ya que en ambos casos la segunda es el doble de la primera (diferencia de una octava musical). Las transformaciones tiempo–frecuencia clásicas como la **Transformada de Fourier de tiempo corto** (STFT) distribuyen las bandas de forma **lineal**, lo que implica que las frecuencias graves que-

dan con poca resolución y las frecuencias agudas con resolución excesiva, algo que no se corresponde ni con la estructura de la música ni con la percepción auditiva.

Es por esto por lo que se usa la **Transformada Q Constante** (*Constant-Q Transform*, CQT), que distribuye las bandas de frecuencia en escala logarítmica, alineándose con la percepción musical y con la disposición de las teclas en el piano [11]. En la CQT, cada *bin* cubre una banda proporcional a su frecuencia central, manteniendo una razón constante entre frecuencia y resolución (Q constante), lo que se traduce en ventanas temporales más largas en bajas frecuencias y más cortas en altas. Esto permite representar de forma más uniforme la energía armónica a lo largo de todo el rango del piano y facilita que la red neuronal aprenda patrones armónicos y melódicos coherentes con la notación musical.

En la Figura 4.1 se puede apreciar este efecto para un mismo fragmento de audio (*Prelude op. 28 no. 16, Chopin*, interpretación original), que presenta una distribución bastante uniforme sobre el piano, con presencia tanto en el registro grave como en el agudo. La STFT lineal agrupa la energía armónica en muy pocas bandas graves, mientras que la CQT asigna un número constante de *bins* por octava, distribuyendo la información de forma mucho más uniforme a lo largo del rango del instrumento. Esta diferencia visual resume la ventaja práctica de la CQT como representación de entrada para la transcripción automática de piano.

La CQT presenta los siguientes parámetros de configuración:

- Frecuencia mínima de 27,5 Hz correspondiente a la tecla A0 (la tecla más grave de un piano estándar).
- 48 *bins* por octava, con un total de 352.
- Ventana de *Hanning* y salto de trama (*hop length*) de 20 ms.

El espectrograma CQT de dimensiones $(T \times 352)$, donde T es el número de *frames*, se remodela a (C_0, T, F) con $C_0 = 4$ y $F = 88$. De esta forma, los 352 *bins* se distribuyen en cuatro grupos de 88 frecuencias, en correspondencia biunívoca con las 88 teclas del piano [11]. Esta representación constituye la entrada de la capa lineal inicial del modelo.

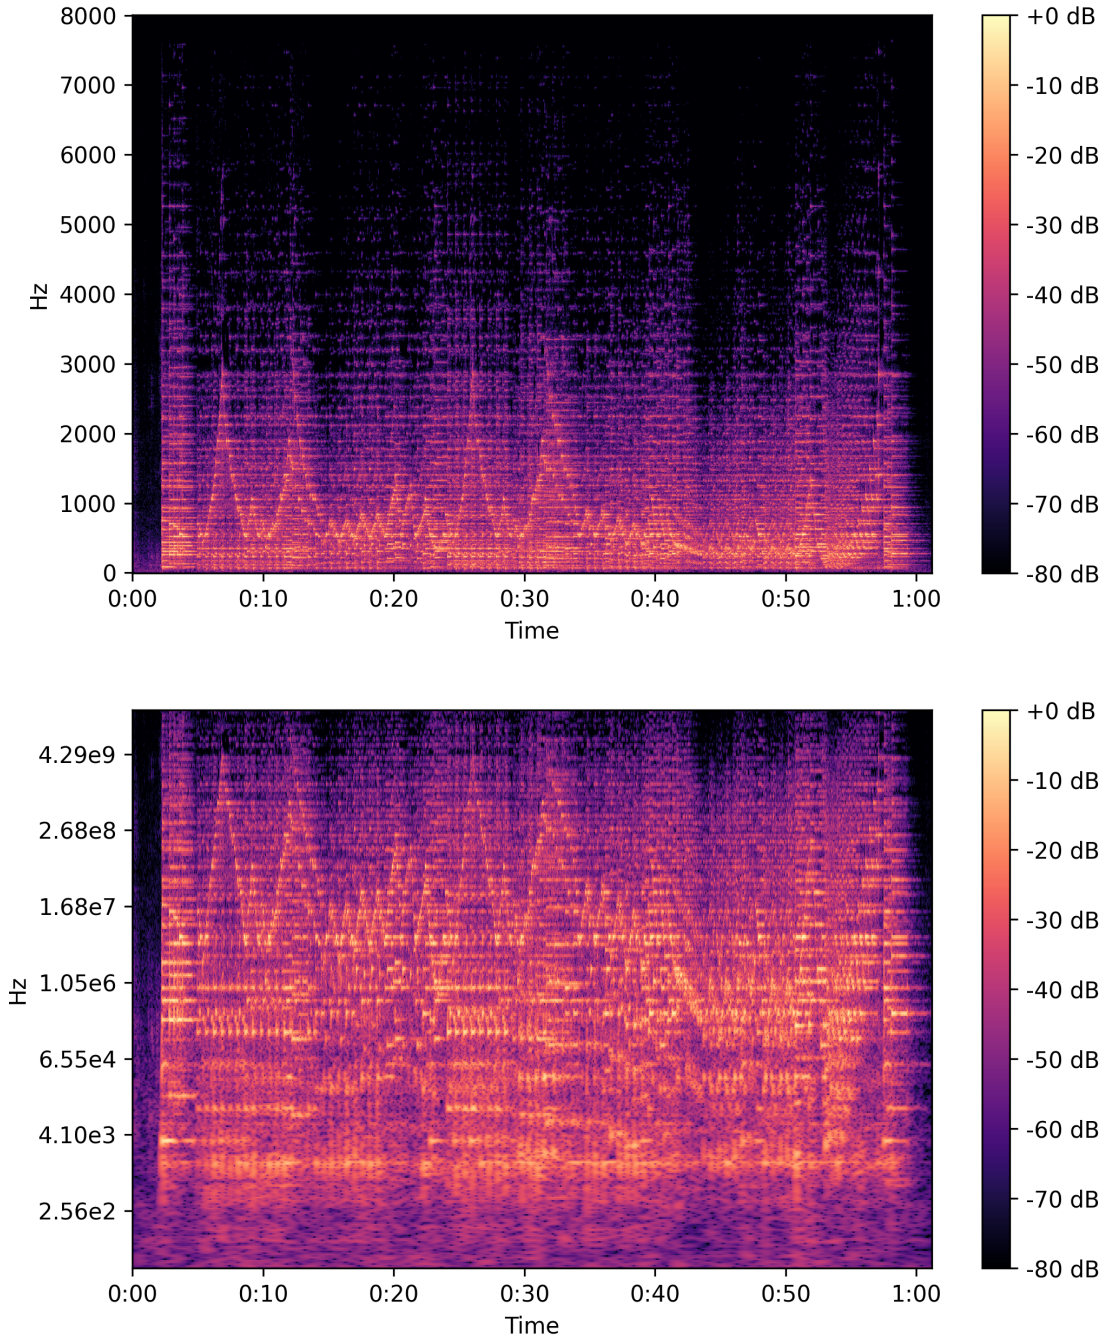


Figura 4.1: Comparación entre un espectrograma STFT con eje de frecuencia lineal y un espectrograma CQT con eje logarítmico, ambos generados a partir del mismo fragmento de audio de piano (*Prelude op. 28 no. 16, Chopin*). En la parte superior se muestra la STFT con escala lineal de frecuencia, donde la energía de los armónicos graves se concentra en muy pocas bandas y las frecuencias agudas aparecen con una resolución excesiva. En la parte inferior se muestra la CQT con escala logarítmica, que asigna un número constante de *bins* por octava y reparte la energía de forma mucho más uniforme a lo largo del teclado, alineando las bandas de frecuencia con las notas discretas del piano. Esta figura ilustra visualmente la motivación principal para emplear la CQT como representación tiempo–frecuencia de entrada en el modelo MFT-FiLM, ya que proporciona una base más adecuada para el aprendizaje de patrones armónicos y la posterior estimación de activaciones de nota.

4.3 Arquitectura general

El modelo MFT-FiLM aborda la transcripción automática de piano como un problema de aprendizaje multitarea con cuatro salidas simultáneas: la activación de teclas a nivel de *frame*, los *onsets*, los *offsets* y la velocidad de las notas [11]. La Figura 4.2 muestra el esquema general del sistema, que sirve de referencia para la descripción del flujo de información que se desarrolla en esta sección.

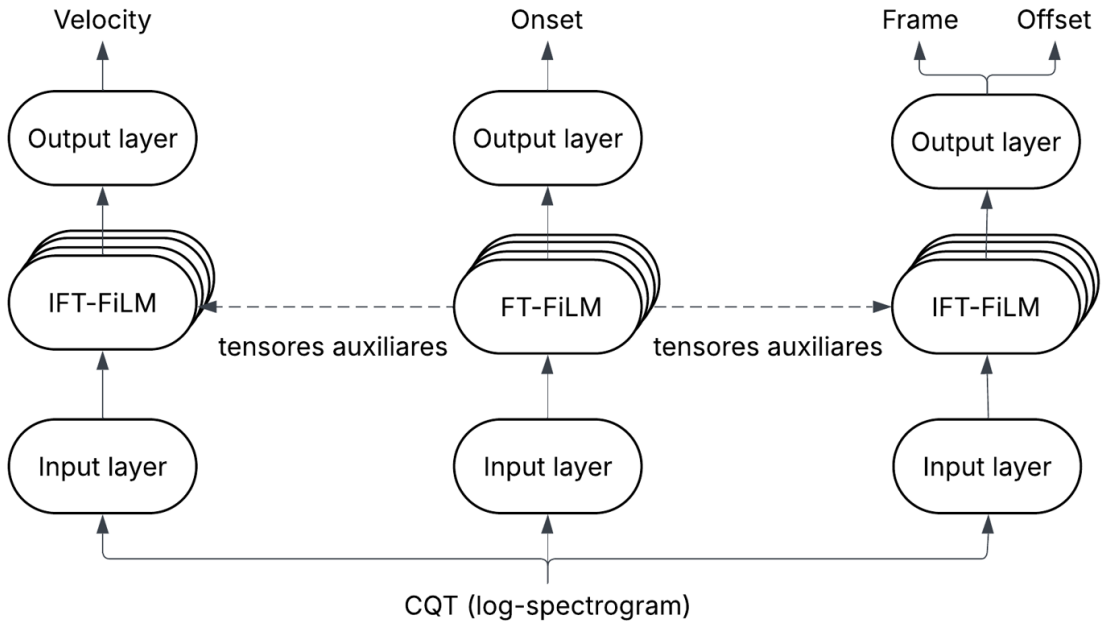


Figura 4.2: Esquema general del modelo MFT-FiLM para la transcripción multitarea de notas de piano, con las tres ramas de *onset*, *velocity* y *frame+offset*, y el flujo de información a través de los bloques FT-FiLM e IFT-FiLM. Ilustración adaptada de [11].

La entrada común a las tres ramas es el espectrograma CQT descrito en la Sección 4.2, con dimensiones (C_0, T, F) donde $C_0 = 4$, T es el número de *frames* y $F = 88$ corresponde a las teclas del piano. Como se aprecia en la parte inferior de la Figura 4.2, este tensor se distribuye de forma idéntica a las tres ramas a través de sus respectivas **capas de entrada** (*Input layer*), que proyectan los $C_0 = 4$ canales al espacio de características interno de cada rama mediante una transformación lineal.

El sistema se organiza en **tres ramas paralelas**, visibles en la Figura 4.2: la rama central de *onset*, la rama izquierda de *velocity* y la rama derecha de *frame+offset*. Cada rama apila **cuatro bloques de modulación** en cascada, representados como bloques apilados en el diagrama. El tipo de bloque varía según la rama: la rama *onset* emplea bloques **FT-FiLM**, mientras que las ramas *velocity* y *frame+offset* emplean bloques **IFT-FiLM**. Las diferencias funcionales entre ambos tipos de bloque se detallan en la Sección 4.4.

Las dimensiones de los canales internos son $C = 64$ en las ramas *onset* y *velocity*, y $C = 32$ en la rama *frame+offset* [11]. Esta asimetría deliberada permite reducir el número total de parámetros sin penalizar la capacidad expresiva de las ramas más discriminativas.

La interacción entre ramas se produce mediante **tensores auxiliares**, representados en la Figura 4.2 mediante flechas discontinuas. En cada uno de los cuatro niveles de procesamiento, los tensores intermedios generados por los bloques FT-FiLM de la rama *onset* se reenvían simultáneamente a los bloques IFT-FiLM de las ramas *velocity* y *frame+offset*. Este flujo es **estrictamente unidireccional**: la información viaja desde la rama *onset* hacia

las otras dos, pero no en sentido contrario. Esta decisión de diseño se justifica porque la señal de *frame* combina activaciones de notas sostenidas y de finales de nota, lo que podría interferir negativamente en la detección precisa de inicios si se empleara como entrada de la rama *onset* [11]. El resultado es un esquema con **cuatro niveles de interacción cruzada**, desde representaciones espectrales de bajo nivel hasta semánticas de alto nivel.

Cada rama dispone de una **capa de salida** (*Output layer*), visible en la parte superior de la Figura 4.2, que adapta las representaciones internas al objetivo de su subtarea. Las salidas del sistema son tres *piano rolls* de probabilidad: la rama *onset* produce un mapa de dimensiones $T \times 88$ con activación sigmoide; la rama *frame+offset* produce dos mapas de igual dimensión para la activación de trama y el final de nota, también con activación sigmoide; y la rama *velocity* produce un mapa de $T \times 88 \times 128$ valores sobre las 128 clases de velocidad MIDI, sin activación final. En conjunto, estas tres salidas permiten reconstruir una transcripción completa en formato MIDI con tono, duración y dinámica de cada nota. El diseño interno de las capas de salida se describe junto con el resto de componentes en la Sección 4.4.

Los *piano rolls* de probabilidad producidos por el modelo no constituyen por sí mismos una transcripción musical: son mapas densos de activaciones continuas sobre los que es necesario aplicar una etapa de postprocesado para obtener eventos de nota discretos con tono, inicio, duración y velocidad.

Durante la inferencia se aplica la estrategia de **medio paso** (*half stride*) [13], que procesa el audio en ventanas con un solapamiento del 50 %. Este solapamiento permite promediar las predicciones en las regiones de transición entre ventanas, mitigando los artefactos en bordes que aparecen al segmentar la señal.

Finalmente, se aplica el **algoritmo de decodificación heurístico de eventos de nota** [5], que convierte los *piano rolls* umbralizados en una secuencia de eventos discretos.

4.4 Módulos FiLM, FT-FiLM e IFT-FiLM

Esta sección describe el mecanismo de modulación que constituye el núcleo computacional del modelo y que da nombre al sistema. Se presentan en orden creciente de complejidad: primero el mecanismo FiLM base, después el módulo FT-FiLM que lo especializa para la extracción de información espectro-temporal, y finalmente el módulo IFT-FiLM que lo extiende para la interacción entre ramas de distintas tareas.

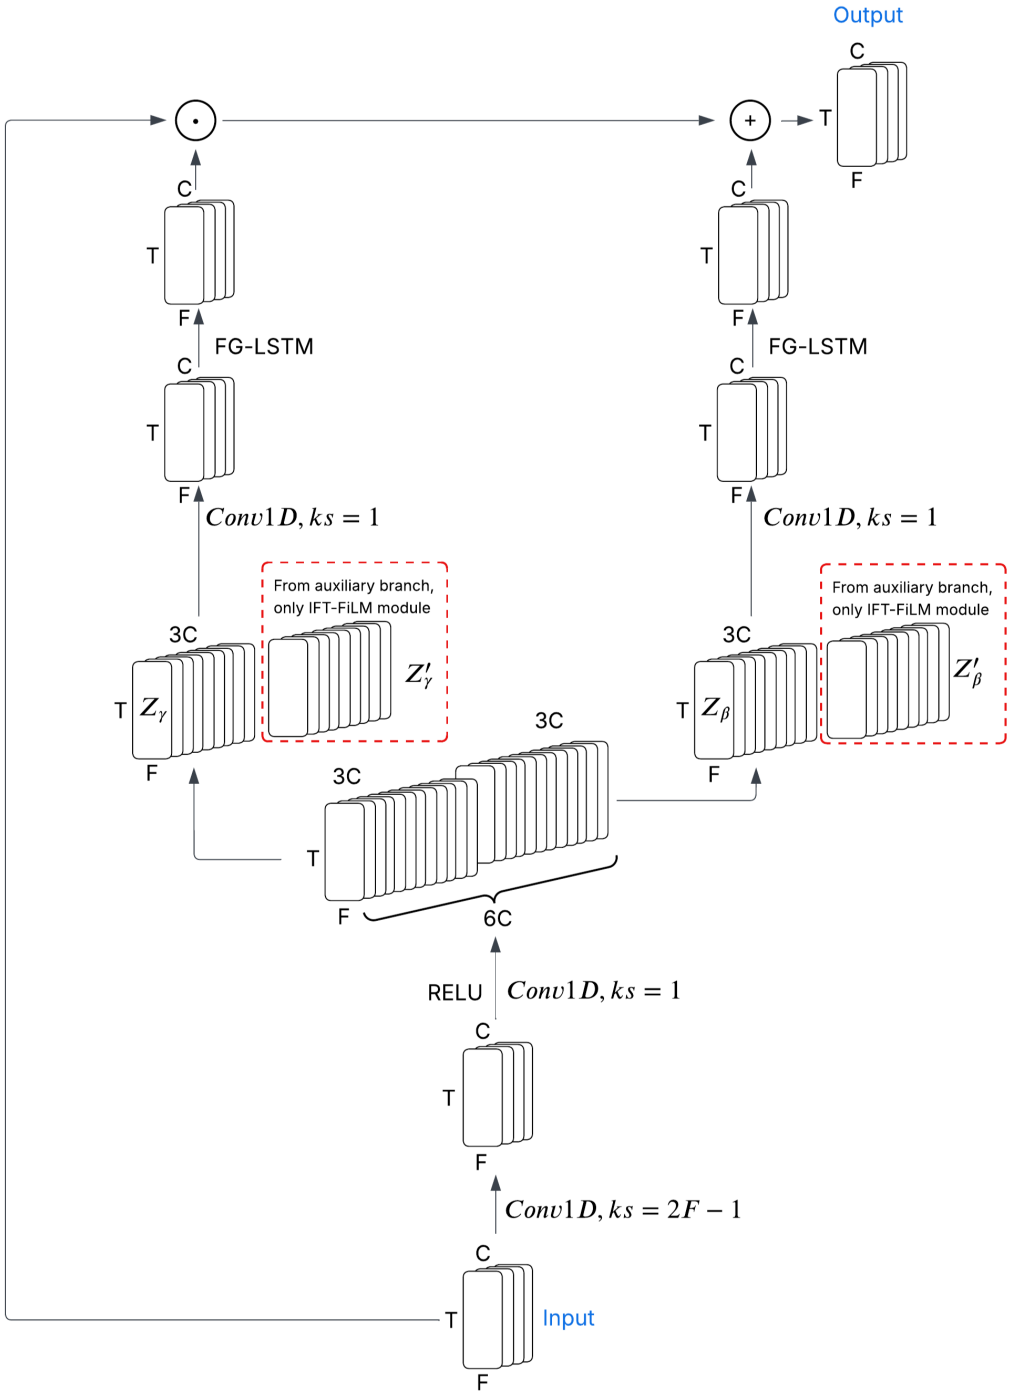


Figura 4.3: Arquitectura detallada de los módulos FT-FiLM e IFT-FiLM. La señal de **entrada** (azul, parte inferior) tiene dimensiones (C, T, F). Una convolución 1D con kernel de tamaño $2F - 1 = 175$ opera sobre el eje de frecuencia; a continuación, una convolución 1D con kernel de tamaño 1 ($k_s = 1$) expande los canales de C a $6C$ y el tensor resultante se divide en dos mitades de $3C$ canales: los parámetros de escala Z_γ y desplazamiento Z_β. En el módulo **IFT-FiLM** (ramas *velocity* y *frame+offset*), los tensores auxiliares Z'_γ y Z'_β procedentes de la rama *onset* (representados con borde discontinuo rojo) se concatenan a los tensores locales, alcanzando $6C$ canales cada uno; en el módulo **FT-FiLM** (rama *onset*) esta concatenación no se produce. Las convoluciones 1D reducen cada tensor de vuelta a C canales, tras lo cual dos **FG-LSTM** bidireccionales independientes de 32 unidades modelan las dependencias temporales, produciendo los parámetros finales γ y β. La transformación afín $\gamma \odot x + \beta$ se aplica sobre la entrada original mediante la conexión de salto (parte superior), generando la **salida** modulada (azul, arriba) de dimensiones (C, T, F). Los tensores auxiliares se desconectan del grafo de cómputo (`detach`) antes de su incorporación para evitar inestabilidades en la optimización. Ilustración adaptada de [11].

El mecanismo *Feature-Wise Linear Modulation* (FiLM) fue propuesto inicialmente por Perez *et al.* (2018) [9] para tareas de razonamiento visual. La idea central consiste en condicionar las activaciones de una red neuronal mediante una transformación afín elemento a elemento, usando información de contexto generada por un módulo externo denominado *FiLM Generator*. Definimos formalmente la operación como:

$$\text{FiLM}(x,\, \gamma,\, \beta) = \gamma \odot x + \beta \tag{4.1}$$

donde x es el mapa de características de entrada, γ y β son los parámetros de escala y desplazamiento generados dinámicamente, y $\odot$ es el producto de Hadamard (multiplicación elemento a elemento). El principal beneficio de este mecanismo respecto a la suma o concatenación directa de características es que γ y β se adaptan en función del contexto en cada paso de inferencia, permitiendo al modelo ponderar y suprimir canales de forma dinámica en lugar de aplicar pesos fijos.

El módulo **FT-FiLM** (*Frequency-Time FiLM*) adapta el mecanismo de la ecuación (4.1) para extraer dependencias espectrales y temporales de forma jerárquica a partir del espectrograma CQT. Es el tipo de bloque empleado en la rama *onset*, que opera exclusivamente sobre su propia representación interna (auto-condicionamiento). Su operación se define como:

$$\text{FT-FiLM}(x) = f_{FT}(x) \odot x + h_{FT}(x) \tag{4.2}$$

donde f_{FT} y h_{FT} son los generadores de los parámetros de modulación γ y β respectivamente. Como se puede seguir en la Figura 4.3, el generador opera en tres etapas secuenciales sobre el mapa de entrada de dimensiones (C, T, F). En primer lugar, el mapa de características se convoluciona con un kernel 1D de tamaño $2F - 1 = 175$ sobre el eje de frecuencia F, seguido de activación RELU. Este kernel se diseña con una longitud igual al doble del eje completo menos uno para capturar simultáneamente las relaciones armónicas entre todos los *bins* de frecuencia del piano, algo que las convoluciones de kernel reducido no pueden lograr [11].

A continuación, los canales se expanden de C a $6C$ mediante una convolución 1D con kernel de tamaño 1. El tensor resultante se divide en dos mitades de $3C$ canales, denominadas Z_γ y Z_β, que posteriormente generarán los parámetros de escala y desplazamiento de la modulación afín. Sobre cada una de ellas se aplica una convolución 1D con kernel de tamaño 1 que reduce los canales de vuelta a C. Los tensores resultantes se procesan entonces con dos redes recurrentes **FG-LSTM** (*Frequency-Grouped LSTM*) bidireccionales independientes, cada una con 32 unidades ocultas, que capturan las dependencias temporales entre *frames* consecutivos a lo largo del eje T. El uso de LSTM bidireccional incorpora tanto el contexto pasado como el futuro en cada instante de la secuencia, produciendo los tensores γ y β finales del generador.

Tras estas tres etapas, el mapa de entrada original x se modula aplicando la transformación afín de la ecuación (4.2), con una capa de *dropout* de tasa 0,1 antes de la modulación final (visible en la Figura 4.3 como la conexión de salto que llega a los operadores $\odot$ y $+$). El resultado es una representación auto-condicionada que integra información espectral y temporal de forma jerárquica y separada, lo que permite mantener un número de parámetros reducido. El generador FiLM gestiona la información en tres dimensiones individuales (frecuencia, canal y tiempo) de forma desacoplada, en lugar de operarlas conjuntamente como haría un mecanismo de atención estándar.

Con el objetivo de permitir la interacción entre ramas de distintas tareas, el módulo **IFT-FiLM** (*Inter-Task FT-FiLM*) extiende el FT-FiLM incorporando información auxi-

liar procedente de otra rama. Es el tipo de bloque empleado en las ramas *velocity* y *frame+offset*. Su operación se define como:

$$\text{IFT-FiLM}(x,\, x') = f_{IFT}(x,\, x') \odot x + h_{IFT}(x,\, x') \tag{4.3}$$

donde x es el mapa de características de la rama principal y x' es la información auxiliar proveniente de la rama *onset*. La arquitectura del IFT-FiLM es idéntica a la del FT-FiLM salvo en el paso de transformación de canales: como se aprecia en la Figura 4.3 mediante los bloques con borde discontinuo rojo, los tensores Z'_γ y Z'_β generados por la rama auxiliar se concatenan a los tensores locales a lo largo del eje de canales, alcanzando $6C$ canales en cada tensor antes de que la convolución 1D con kernel de tamaño 1 los reduzca de vuelta a C. De este modo, la etapa de FG-LSTM y la modulación afín final operan sobre una representación que ya ha fusionado la información de ambas ramas.

Un detalle de implementación relevante es que los tensores auxiliares Z'_γ y Z'_β se **desconectan del grafo de cómputo** (`detach`) antes de ser incorporados [11]. Esta operación impide que el gradiente fluya de vuelta hacia la rama *onset* a través de esta conexión, evitando inestabilidades en la optimización. El módulo IFT-FiLM puede interpretarse como una red neuronal dinámica: los parámetros de modulación no son fijos, sino que se generan en cada paso en función de las entradas de ambas ramas, permitiendo que la red adapte su comportamiento de acuerdo con el contexto conjunto de las tareas involucradas [11].

4.5 Función de pérdida y eficiencia

La función de pérdida del sistema es la suma de las pérdidas individuales de cada subtarea:

$$\ell = \ell_{\text{onset}} + \ell_{\text{frame}} + \ell_{\text{offset}} + \ell_{\text{velocity}} \tag{4.4}$$

Las pérdidas de *onset*, *frame* y *offset* se calculan mediante **entropía cruzada binaria** (BCE), apropiada para clasificación binaria píxel a píxel del piano roll:

$$\ell_{\text{onset}} = \sum_{k=1}^{K} \sum_{t=1}^{T} \ell_{\text{BCE}}(I_{\text{onset}}(t,k),\ P_{\text{onset}}(t,k)) \tag{4.5}$$

y análogamente para ℓ_{frame} y ℓ_{offset}. La pérdida de velocidad se calcula mediante **entropía cruzada categórica** (CCE) sobre 128 clases, dado que la velocidad MIDI es un valor entero en el intervalo $[0, 127]$:

$$\ell_{\text{velocity}} = \sum_{k=1}^{K} \sum_{t=1}^{T} \ell_{\text{CCE}}\big(I_{\text{velocity}}(t,k),\ P_{\text{velocity}}(t,k)\big) \tag{4.6}$$

donde I y P representan los valores de *ground truth* y predicción respectivamente, $K = 88$ es el número de teclas del piano y T el número de *frames* [11]. La ausencia de factores de ponderación entre las cuatro pérdidas es una elección de diseño deliberada por los autores, cuya validez queda respaldada por el estudio de ablación presentado en la sección de resultados [11].

Una de las aportaciones más destacadas del modelo es su reducido tamaño. Con tan solo 1,2 **millones de parámetros**, el MFT-FiLM se sitúa como uno de los modelos de transcripción de piano más eficientes del estado del arte. En términos de operaciones de multiplicación-acumulación (MACs), calculadas para una salida de 128 *frames* con la

biblioteca `ptflops`, el MFT-FiLM registra una complejidad notablemente inferior a la de otros modelos como el hFT-Transformer o el SemiCRF V2 [11, 13, 16].

Esta eficiencia no sacrifica capacidad expresiva gracias al diseño jerárquico del generador FiLM, que desacopla el procesamiento en los ejes de frecuencia, canal y tiempo en lugar de operarlos conjuntamente. La separación de estas dimensiones permite reutilizar módulos ligeros (convoluciones 1D y LSTMs de baja dimensionalidad) en lugar de recurrir a mecanismos de atención de complejidad cuadrática, sin renunciar a la capacidad de capturar dependencias espectrales y temporales de largo alcance.

4.6 Experimentos

Los experimentos de entrenamiento y evaluación del modelo MFT-FiLM se han llevado a cabo en el clúster de cómputo de alto rendimiento `tensor` del DSIC. La descripción detallada del entorno hardware y software, así como de la configuración del experimento, se recoge en el Anexo A.

Antes del entrenamiento, se ejecuta una fase de **preprocesamiento y caché** del *dataset*. Durante esta fase se transforma cada audio del conjunto MAESTRO en su espectrograma CQT mediante la librería `librosa` y los archivos MIDI correspondientes son procesados mediante `pretty_midi` para generar los *piano rolls* de *ground truth* (véase la Sección A.4 del Anexo A para una descripción de estas herramientas).

Adicionalmente, la duración de cada nota en el *ground truth* se extiende en función de la información de los pedales de *sustain* y *sostenuto*, siguiendo el criterio habitual en transcripción automática de piano: una nota se prolonga hasta que el valor del pedal de *sustain* en el archivo MIDI cae por debajo de 64, o hasta que la misma tecla es pulsada de nuevo. Este paso es crucial para la fidelidad del *ground truth*, ya que en interpretaciones de piano con pedal las notas resuenan durante más tiempo del que dura la pulsación física de la tecla; ignorar esta información produciría un *ground truth* sistemáticamente más corto que el audio real.

El resultado de la fase de preprocesamiento es un conjunto de archivos binarios en disco que almacenan, para cada fragmento de audio, el espectrograma CQT y los correspondientes mapas de activación de nota. Estos archivos de caché se reutilizan directamente en todos los entrenamientos subsiguientes, de modo que el costoso cálculo de las representaciones tiempo–frecuencia y de los *piano rolls* sólo se realiza una vez.

A continuación se analizan los resultados obtenidos por el modelo MFT-FiLM entrenado sobre MAESTRO v3.0.0. Las métricas empleadas coinciden con el protocolo estándar descrito en la Sección 3.9: se evalúa el rendimiento a nivel de trama y a nivel de nota mediante precisión, *recall* y puntuación F_1, tanto para la activación de teclas (*Frame*) como para las variantes *Note Onset*, *Note w/ Offset* y *Note w/ Offset & Velocity* [11, 16].

Para garantizar la comparabilidad directa con los trabajos originales, las predicciones de MFT-FiLM se umbralizan utilizando los mismos valores que en el repositorio de referencia. En todas las evaluaciones se fijan los umbrales de decisión a $t_{\text{onset}} = 0{,}4$, $t_{\text{frame}} = 0{,}48$ y $t_{\text{offset}} = 0{,}5$ [11].

Las Tablas 4.1, 4.2 y 4.3 muestran una comparación cuantitativa de los resultados obtenidos sobre MAESTRO v3.0.0, incluyendo las métricas de F_1, precisión y *recall*, respectivamente. Se compara el modelo entrenado con otros modelos SOTA.

Tabla 4.1: Resultados de transcripción de notas sobre MAESTRO v3.0.0. Se muestran el número de parámetros y las puntuaciones F_1 a nivel de trama (*Frame*) y de nota (*Note Onset*, *Note w/ Offset*, *Note w/ Offset & Velocity*). Todas las métricas se expresan en porcentaje (%).

Modelo	Parámetros	Frame F_1	Onset F_1	Onset+Off. F_1	Onset+Off.+Vel. F_1
Transformer [12]	54 M	—	96.01	83.94	82.75
SemiCRF [15]	9 M	90.75	96.11	88.42	87.44
HPPNet [14]	1.2 M	93.15	97.18	83.80	82.24
hFT-Transformer [13]	5.5 M	93.24	97.44	90.53	89.48
HATANet [10]	6.4 M	94.04	97.81	90.57	89.25
SemiCRF V2 [16]	12.9 M	95.35	98.32	93.48	92.94
MFT-FiLM (autores) [11]	1.2 M	94.75	98.39	92.46	91.79
MFT-FiLM (este trabajo)	1.2 M	94.36	98.17	91.60	90.78

En la Tabla 4.1 se observa que el modelo MFT-FiLM entrenado alcanza unas puntuaciones F_1 muy próximas a las reportadas por los autores originales en MAESTRO v3.0.0 [11]. A pesar de haber completado únicamente 30 de las 60 épocas de entrenamiento descritas en el artículo, el F_1 de trama se mantiene por encima del 94 %, mientras que las métricas de nota alcanzan valores superiores al 98 % en *Note Onset* y en torno al 91–91,5 % en *Note w/ Offset* y *Note w/ Offset & Velocity*. Estas diferencias de unas pocas décimas respecto a los resultados publicados pueden atribuirse tanto a la reducción del número de épocas como a las pequeñas divergencias en el entorno de cómputo (ver Anexo A).

Tabla 4.2: Resultados de precisión (P) de transcripción de notas sobre MAESTRO v3.0.0. Se muestran el número de parámetros y las métricas de precisión a nivel de trama (*Frame*) y de nota (*Note Onset*, *Note w/ Offset*, *Note w/ Offset & Velocity*). Todas las métricas se expresan en porcentaje (%).

Modelo	Parámetros	Frame P	Onset P	Onset+Off. P	Onset+Off.+Vel. P
Transformer [12]	54 M	—	98.61	86.19	84.95
SemiCRF [15]	9 M	93.79	98.69	90.79	89.78
HPPNet [14]	1.2 M	92.79	98.45	84.88	83.29
hFT-Transformer [13]	5.5 M	92.82	99.64	92.52	91.43
HATANet [10]	6.4 M	95.51	99.05	91.70	90.35
SemiCRF V2 [16]	12.9 M	95.75	99.53	94.61	94.07
MFT-FiLM (autores) [11]	1.2 M	95.77	99.33	93.33	92.65
MFT-FiLM (este trabajo)	1.2 M	95.27	99.37	92.70	91.86

Tabla 4.3: Resultados del *recall* (R) en transcripción de notas sobre MAESTRO v3.0.0. Se muestran el número de parámetros y las métricas de *recall* a nivel de trama (*Frame*) y de nota (*Note Onset*, *Note w/ Offset*, *Note w/ Offset & Velocity*). Todas las métricas se expresan en porcentaje (%).

Modelo	Parámetros	Frame R	Onset R	Onset+Off. R	Onset+Off.+Vel. R
Transformer [12]	54 M	—	93.60	81.86	80.70
SemiCRF [15]	9 M	88.36	93.96	86.46	85.51
HPPNet [14]	1.2 M	93.59	95.95	82.76	81.24
hFT-Transformer [13]	5.5 M	93.66	95.44	88.69	87.67
HATANet [10]	6.4 M	92.62	96.61	89.47	88.17
SemiCRF V2 [16]	12.9 M	95.01	97.16	92.39	91.87
MFT-FiLM (autores) [11]	1.2 M	93.84	97.48	91.62	90.95
MFT-FiLM (este trabajo)	1.2 M	93.56	97.03	90.54	89.73

Las Tablas 4.2 y 4.3 descomponen el F_1 en términos de precisión y *recall*. En la reproducción se observa una precisión especialmente alta en la detección de inicios de nota, cercana al 99 %, lo que indica que el modelo apenas introduce notas espurias que no existen en la partitura de referencia. El *recall* en onsets se sitúa ligeramente por debajo,

en torno al 97 %, lo que sugiere que los pocos errores restantes se deben principalmente a notas omitidas en pasajes complejos más que a activaciones falsas.

En las métricas que incluyen el *offset* y la velocidad, tanto la precisión como el *recall* descienden de forma moderada pero se mantienen en torno al 90 %, en línea con los resultados de MFT-FiLM reportados por Wang *et al.* [11] y con los mejores modelos del estado del arte. Esto refleja la mayor dificultad de estimar con precisión el final de las notas y su dinámica en presencia del pedal de *sustain*, pero confirma que la arquitectura MFT-FiLM es capaz de modelar de forma consistente la articulación temporal y la intensidad de la interpretación, incluso cuando el entrenamiento se detiene a mitad de las épocas previstas.

Finalmente, la comparación horizontal de las tres tablas evidencia que, con solo 1,2 millones de parámetros, la variante reproducida de MFT-FiLM ofrece un rendimiento muy cercano al de modelos considerablemente más pesados, como hFT-Transformer o las variantes SemiCRF. Desde la perspectiva de la relación entre eficiencia y precisión, este comportamiento respalda la tesis de los autores de que la modulación lineal frecuencia–tiempo permite explotar de forma eficaz la información compartida entre tareas sin necesidad de incrementar el tamaño del modelo.

De forma complementaria a la evaluación del rendimiento final sobre el conjunto de prueba, el análisis de las métricas durante el proceso de entrenamiento resulta fundamental para comprender el comportamiento analítico y la eficiencia de aprendizaje de la arquitectura MFT-FiLM. Con este propósito, se ha monitorizado la evolución de la función de pérdida (*loss*) y de las métricas de validación a lo largo de las 30 épocas completadas. En primer lugar se analiza la dinámica de la pérdida dentro de la primera época de entrenamiento (Figura 4.4), que proporciona información detallada sobre la fase de adaptación inicial del modelo.

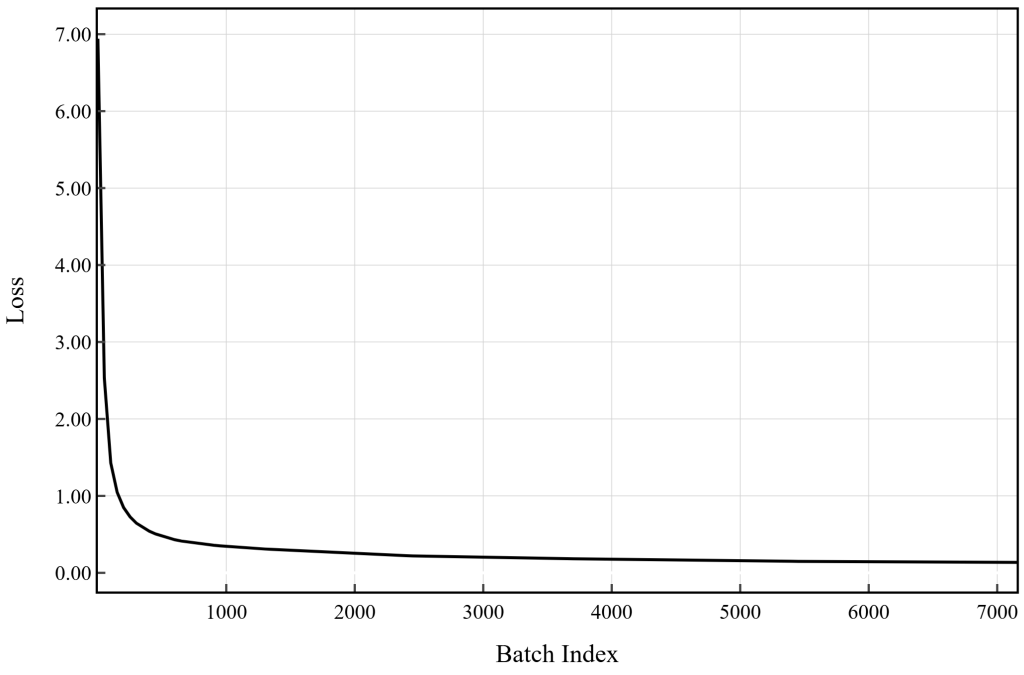


Figura 4.4: Evolución de la función de pérdida lote a lote durante la primera época de entrenamiento del modelo MFT-FiLM. Se aprecia un descenso abrupto en las primeras iteraciones seguido de una estabilización progresiva, lo que indica que el mecanismo FiLM facilita una adaptación inicial muy rápida a las representaciones espectro-temporales de la señal de audio.

La Figura 4.4 muestra que el modelo exhibe una convergencia inicial excepcionalmente rápida. Durante las primeras iteraciones de la primera época, la función de pérdida experimenta un descenso abrupto seguido de una estabilización progresiva, lo que sugiere que el mecanismo FiLM facilita una adaptación veloz a las representaciones espectrotemporales de la señal de audio. Este patrón es consistente con un régimen de aprendizaje en el que los parámetros del modelo se ajustan con rapidez a la estructura básica de los datos, mientras que las etapas posteriores de la época se dedican a refinar gradualmente las representaciones internas sin oscilaciones ni comportamientos inestables.

A continuación se analiza la evolución macroscópica de la pérdida de entrenamiento y validación a lo largo de las 30 épocas completadas (Figura 4.5), con el fin de valorar la estabilidad global del proceso de optimización y la posible aparición de sobreajuste.

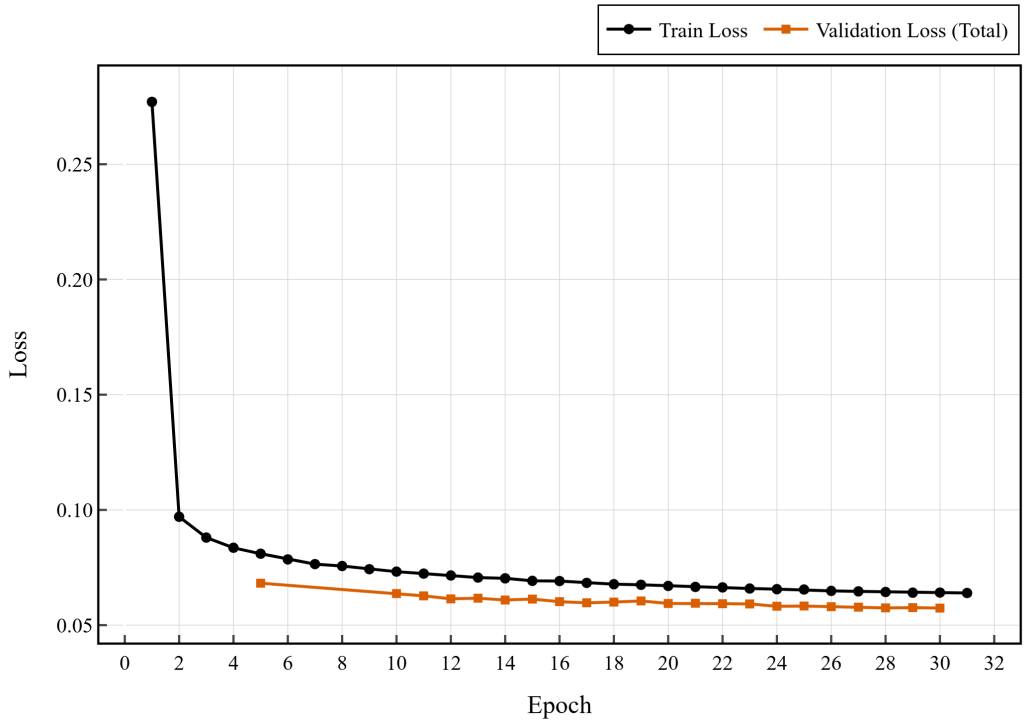


Figura 4.5: Pérdida promedio de entrenamiento frente a pérdida de validación a lo largo de las 30 épocas completadas (calculada como la suma de los errores de las cuatro subtareas: *onset*, *frame*, *offset* y *velocity*). La pérdida de entrenamiento decrece de forma asintótica de 0,277 en la época 1 a 0,063 en la época 30, y la pérdida de validación acompaña esta tendencia sin divergir, descartando la presencia de sobreajuste en esta etapa del entrenamiento.

Al analizar la Figura 4.5, se observa que la pérdida de entrenamiento continúa decreciendo de forma monótona y asintótica, reduciéndose de 0,277 en la época 1 a 0,063 en la época 30. La curva de validación acompaña esta trayectoria con valores ligeramente superiores pero paralelos, sin presentar la separación creciente característica del sobreajuste. Este comportamiento indica que, en el rango de épocas ejecutado, el modelo sigue mejorando su capacidad de generalización y no ha agotado aún su potencial de aprendizaje; de hecho, cabe esperar una ligera mejora adicional de las métricas si el entrenamiento se prolongara hasta las 60 épocas planificadas en el trabajo original.

Continuamos analizando métricas en validación. La Figura 4.6 desglosa la evolución de la métrica F_1 sobre el conjunto de validación para las cuatro subtareas evaluadas.

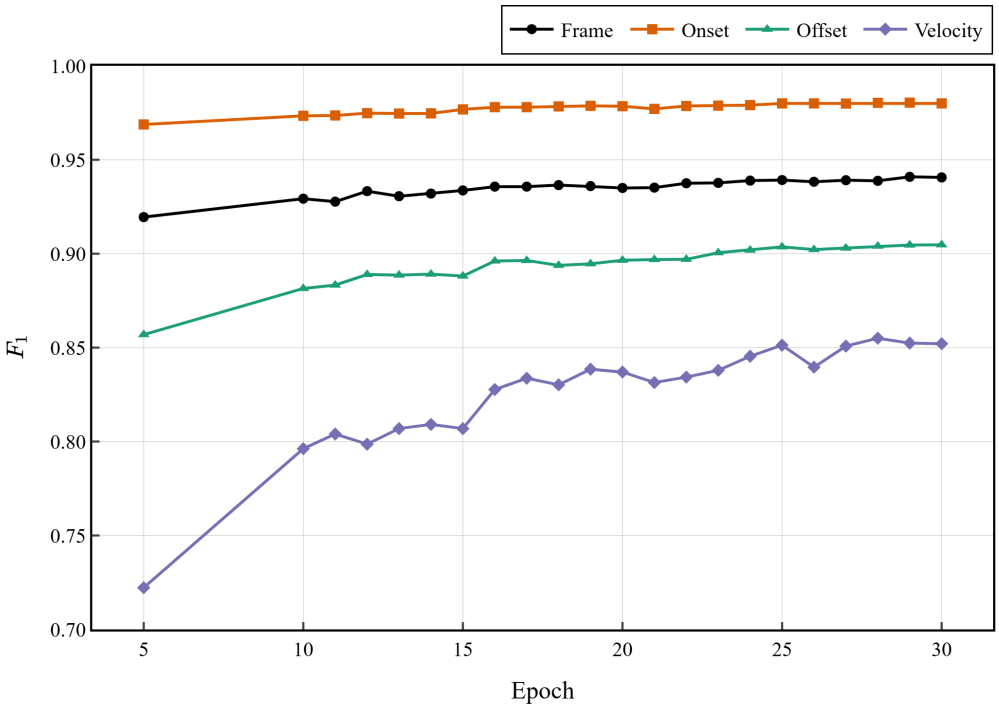


Figura 4.6: Evolución de la métrica F_1 en el conjunto de validación para la estimación de *Frame*, *Onset*, *Offset* y *Velocity* durante las 30 épocas de entrenamiento. Se aprecia una convergencia rápida y estable en las tareas de *Frame*, *Onset* y *Offset*, mientras que la tarea de *Velocity* presenta una mejora más gradual asociada a la mayor complejidad de modelar la dinámica de la interpretación.

En la Figura 4.6 se observa una estructura jerárquica de aprendizaje bien definida: la detección de *Note Onset* alcanza valores de convergencia superiores al 97 % de forma muy temprana (época 5). En contraste, la estimación de la velocidad (*Velocity*), al constituir un problema de regresión dependiente de la intensidad dinámica de la pulsación, requiere un proceso de optimización más prolongado, evolucionando desde un 72,22 % inicial hasta consolidarse por encima del 85 % hacia la culminación del entrenamiento. Esta diferencia de ritmos de convergencia es coherente con la dificultad relativa de cada subtarea y confirma que la arquitectura es capaz de capturar primero la estructura temporal de los eventos de nota y, en una segunda fase, refinar la estimación de su dinámica.

Para analizar rigurosamente la naturaleza de las predicciones del modelo, resulta necesario descomponer esta métrica armónica en sus constituyentes básicos. La Figura 4.7 presenta en paralelo los niveles de precisión y *recall* obtenidos durante la fase de validación.

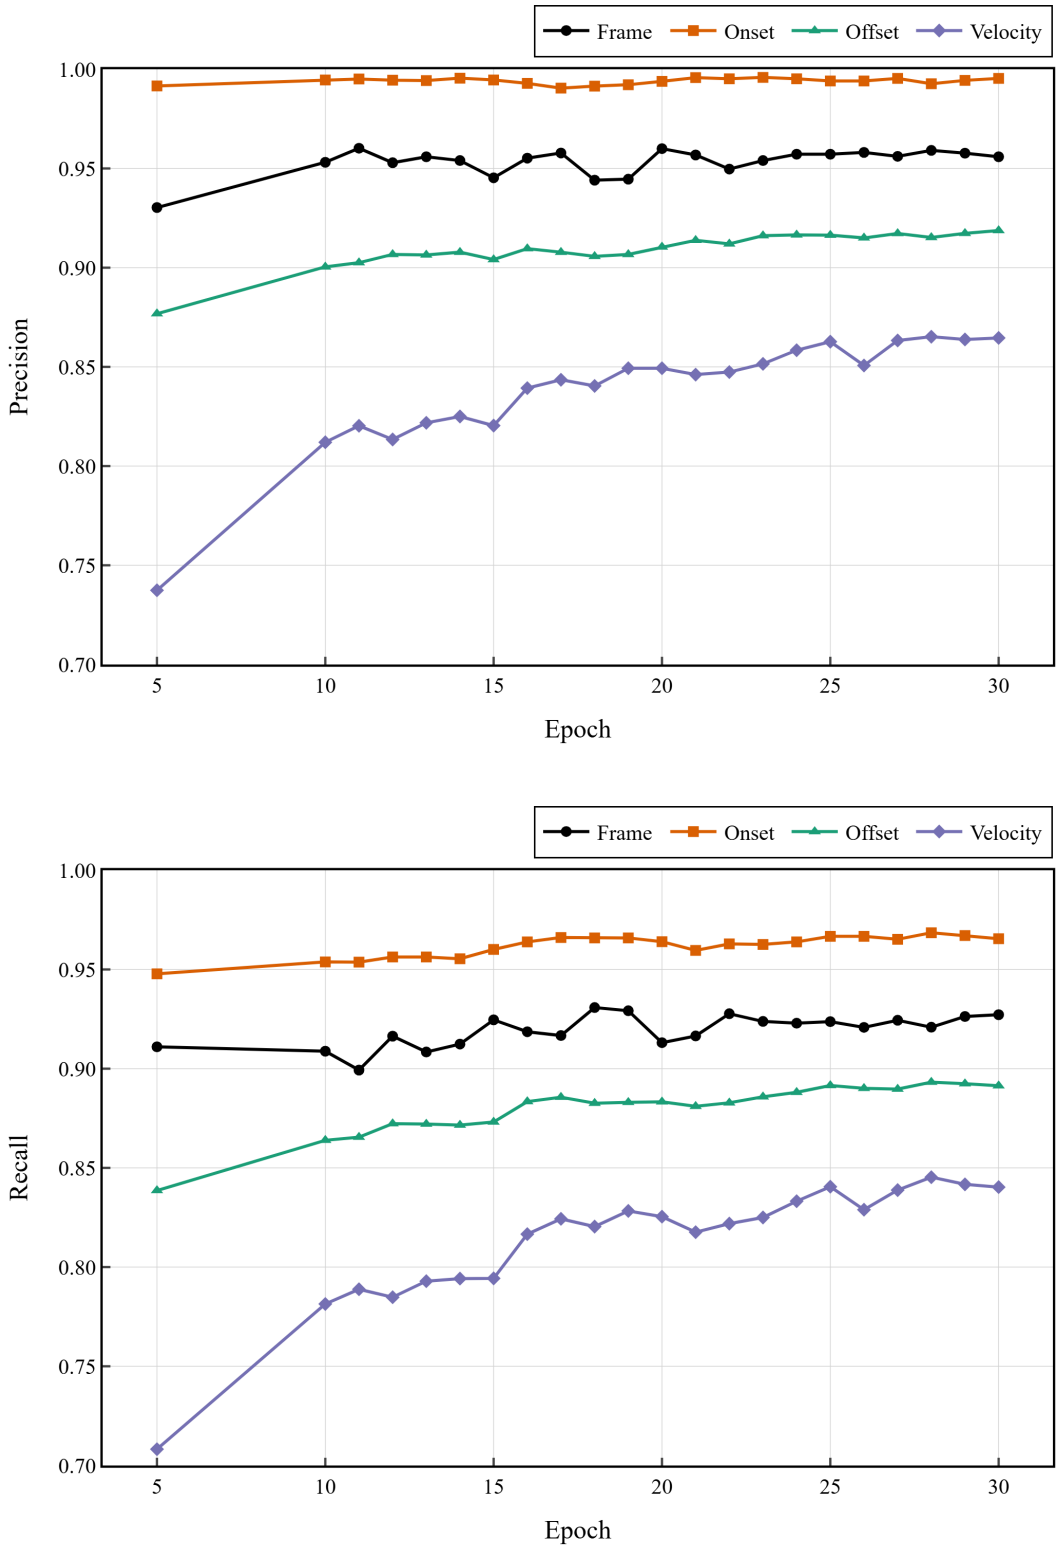


Figura 4.7: Evolución de la precisión (arriba) y del *recall* (abajo) en el conjunto de validación a lo largo de las 30 épocas de entrenamiento, desglosadas por subtarea: *Frame*, *Onset*, *Offset* y *Velocity*. La precisión se mantiene de forma sistemática por encima del *recall* en todas las tareas y épocas, reflejando un comportamiento conservador del modelo: ante la incertidumbre, el sistema prefiere omitir una nota a activar una inexistente. En la época 30, la precisión de *Onset* alcanza valores cuasi perfectos ($>$ 99,5 %), mientras que el *recall* de la misma subtarea se estabiliza en torno al 96,5 %. Esta divergencia indica que los errores residuales provienen principalmente de notas omitidas en pasajes de alta densidad polifónica, y no de activaciones falsas.

El contraste analítico entre ambas gráficas de la Figura 4.7 evidencia que el modelo MFT-FiLM presenta un comportamiento marcadamente **conservador**. A lo largo de todas las épocas y tareas evaluadas, los niveles de precisión se mantienen de forma sistemática por encima de los niveles de *recall*. A modo de ejemplo, en la época 30, la precisión para la detección de *Note Onset* alcanza valores cuasi perfectos ($> 99{,}5\,\%$), mientras que la exhaustividad (*recall*) se estabiliza en torno al 96,5 %.

Estadísticamente, esta divergencia indica que el modelo penaliza con mayor severidad los falsos positivos frente a los falsos negativos. En el contexto específico de la Transcripción Automática de Música (AMT), esto se traduce en que, ante la predicción de activación de una nota, existe una elevada probabilidad de que dicha nota esté efectivamente presente en la interpretación original. En consecuencia, los errores residuales del sistema provienen mayoritariamente de la omisión de notas (*missed notes*), fenómeno particularmente predecible en segmentos de alta densidad polifónica o ante pulsaciones de baja amplitud acústica enmascaradas por el uso del pedal de *sustain*.

Desde una perspectiva de percepción musical, este sesgo algorítmico resulta altamente favorable. En la reconstrucción auditiva de una partitura transcrita (por ejemplo, mediante la síntesis de los archivos MIDI resultantes), la inserción de notas incorrectas o inexistentes (falsos positivos) genera un impacto acústico muy disruptivo y disonante para el oyente. Por el contrario, la omisión puntual de una nota interna dentro de un clúster armónico complejo (falso negativo) tiende a resultar perceptualmente imperceptible, garantizando así la preservación de la coherencia tonal y rítmica de la obra.

4.7 Conclusiones

El modelo MFT-FiLM abordado en este capítulo propone una arquitectura de transcripción multitarea de piano basada en la Transformada Q Constante como representación de entrada, una organización en ramas paralelas para *frame*, *onset*, *offset* y *velocity*, y un mecanismo de modulación FiLM especializado en los módulos FT-FiLM e IFT-FiLM. Este diseño permite desacoplar el procesamiento en los ejes de frecuencia, canal y tiempo, explotando de forma eficiente las dependencias espectrales y temporales sin recurrir a mecanismos de atención de alta complejidad [11].

Desde el punto de vista cuantitativo, la reproducción del experimento sobre MAESTRO v3.0.0 alcanza puntuaciones F_1, de precisión y de *recall* muy próximas a las reportadas por los autores originales, a pesar de que el entrenamiento solo completó 30 de las 60 épocas previstas. El modelo mantiene un F_1 de trama superior al 94 % y métricas de nota en torno al 91–91,5 % para las variantes más exigentes (*Note w/ Offset* y *Note w/ Offset & Velocity*), lo que sitúa a MFT-FiLM como una alternativa competitiva frente a modelos considerablemente más pesados, con únicamente 1,2 millones de parámetros [11, 16].

En cuanto al proceso de optimización, la evolución de la pérdida de entrenamiento y validación muestra una convergencia estable y sin indicios de sobreajuste en las 30 épocas completadas, con una reducción asintótica de la pérdida total y un acompañamiento estrecho por parte de la pérdida de validación. De forma complementaria, el análisis de las métricas en validación revela un comportamiento sistemáticamente conservador del modelo, con niveles de precisión que superan de forma consistente al *recall* en todas las subtareas, lo que indica que MFT-FiLM prioriza evitar falsas activaciones frente a la recuperación exhaustiva de todas las notas.

Este sesgo conservador resulta especialmente favorable desde una perspectiva perceptual: en la síntesis de las transcripciones resultantes, la ausencia ocasional de notas internas dentro de acordes densos tiende a ser poco perceptible, mientras que la introduc-

ción de notas espurias genera artefactos disonantes claramente audibles. En conjunto, los resultados numéricos y el comportamiento analítico del entrenamiento confirman que la arquitectura MFT-FiLM constituye una solución eficiente y robusta para la transcripción automática de piano, capaz de aproximarse al estado del arte con un coste computacional significativamente reducido.

CAPÍTULO 5
Transkun

5.1 Introducción

La transcripción automática de música de piano puede abordarse desde múltiples perspectivas metodológicas. El enfoque más extendido en la literatura consiste en trabajar a nivel de *frame* (como el MFT-FiLM estudiado en el capítulo anterior): el sistema produce, para cada instante de la señal de audio, una estimación de la activación de cada tecla del piano, del inicio y del final de cada nota (*onset* y *offset*), así como de la velocidad de pulsación (*velocity*) [5, 8]. Estas estimaciones se obtienen de forma independiente para cada subtarea y, a continuación, se ensamblan mediante algoritmos heurísticos de post-procesado (umbralización, búsqueda de picos, modelos de Markov de bajo orden) para recuperar los eventos de nota como intervalos discretos [18]. Por otro lado, hay modelos que tratan de aprender directamente (saltando el *frame level*) qué intervalos de tiempo corresponden a eventos musicales completos, como presentamos a continuación.

En este proyecto, la segunda alternativa implementada es **Transkun** (*Transcription Using Neural semi-CRFs*), propuesto por Yan y Duan4 [16]. La idea central consiste en tratar cada nota como un intervalo cerrado $[i, j]$ sobre el eje temporal, y asignar a cada candidato de intervalo una puntuación escalar que refleje su probabilidad de corresponder a un evento real del tipo de evento dado [16].

En este capítulo, la Sección 5.2 describe la arquitectura completa del sistema, desde el espectrograma de entrada hasta el transformer encoder y los *event tracks*. La Sección 5.5 presenta el *framework* semi-CRF y la formulación del *scoring* por producto interior escalado, incluyendo su justificación teórica. La Sección 5.6 detalla la predicción de atributos por evento y la estrategia de procesado por segmentos. En la Sección 5.8 se describe el preprocesamiento del *dataset* y el desarrollo práctico del entrenamiento en el clúster. Finalmente, la Sección 5.9 presenta y analiza los resultados obtenidos, comparando el rendimiento con el estado del arte y con el modelo MFT-FiLM.

5.2 Arquitectura general

La arquitectura de Transkun transforma el espectrograma log-mel de la señal de audio en un conjunto de intervalos temporales no solapados, uno por tipo de evento, en una única etapa de extremo a extremo. El sistema puede dividirse en cinco etapas funcionales que se aprecian en la Figura 5.1: **(1)** el cálculo del espectrograma de entrada con sobremuestreo de ventanas; **(2)** el submuestreo convolucional y la adición de *embeddings* de posición espacial, en paralelo con la inicialización de los *event tracks*; **(3)** el procesado conjunto mediante un *transformer encoder* no jerárquico; **(4)** el remuestreo temporal de los

event tracks y el *scoring* por producto interior; y **(5)** la decodificación mediante la capa semi-CRF y la predicción de atributos. Las secciones siguientes desarrollan cada una de estas etapas en detalle.

5.3 Espectrograma de entrada, submuestreo y *event tracks*

Esta sección describe las tres primeras etapas del sistema, visibles en la mitad inferior de la Figura 5.1: el cálculo del espectrograma de entrada, el submuestreo convolucional con adición de embeddings de posición espacial, y la inicialización de los *event tracks*.

La señal de audio de entrada se muestrea a 44 100 Hz y se transforma mediante la Transformada de Fourier de Tiempo Corto (STFT) con ventana de *Hanning*, tamaño de ventana de 4096 muestras y un salto de trama (*hop size*) de 1024 muestras ($\approx$ 23,2 ms por trama). Se utilizan 229 bandas mel en el rango de 30 a 8000 Hz [16]. Aunque el mecanismo de transformación espectral es el mismo que en el MFT-FiLM (véase la Sección 4.3), Transkun no emplea la CQT sino el espectrograma log-mel, ya que opera a 44 100 Hz y su *backbone transformer* no requiere la estructura de octavas de la CQT.

Para mejorar la resolución temporal de la representación espectral sin reducir el salto de trama, se aplica una estrategia de **sobremuestreo de ventanas** (*multi-window oversampling*) heredada del semi-CRF original [15]: en lugar de una única ventana de *Hanning* por trama, se aplican **cinco subventanas de Hanning ajustables** (inicializadas con centros equidistantes y varianza constante) sobre cada trama de audio, y sus espectros log-mel resultantes se concatenan a lo largo del eje de canales. El resultado es una entrada de cinco canales espectrales por *bin* tiempo-frecuencia, con dimensiones $(T \times F \times 5)$, tal como indica la Figura 5.1 en la base del diagrama. Cada segmento de audio procesado tiene una duración de 16 segundos [16].

A diferencia de los sistemas SOTA previos (incluyendo el semi-CRF original [15], hFT-Transformer [13] y Onsets & Frames [5]), que preservan la resolución temporal completa de la entrada a lo largo de toda la red, Transkun adopta un diseño de **mapa de características de baja resolución**, análogo al empleado en los Vision Transformers (ViT) [17]. Esta elección de diseño se justifica en que la alta dimensionalidad de los embeddings permite mantener suficiente capacidad expresiva incluso con resolución temporal reducida, al tiempo que el coste computacional del transformer se reduce de forma drástica [16, 22].

El espectrograma de entrada $(T \times F \times 5)$ se submuestrea mediante **cuatro capas convolucionales *strided*** con kernel de tamaño 3 y canales de salida $[128, 256, 256, 256]$ respectivamente (la primera capa actúa como proyección inicial de los 5 canales de entrada). Los *strides* aplicados sobre los ejes de tiempo y frecuencia son $[(2,1), (2,2), (2,2), (1,1)]$, lo que produce un factor de submuestreo de $c_T = 8$ en tiempo y de $c_F = 4$ en frecuencia. El resultado es un mapa de características de baja resolución de dimensiones:

$$(T', F') = \left(\frac{T}{8}, \frac{F}{4}\right) \tag{5.1}$$

equivalente a parches de tamaño 8×4 sobre el espectrograma original [16]. Cada capa convolucional va seguida de una normalización **GroupNorm** con 4 grupos y una activación GELU, a excepción de la última capa. El espectrograma submuestreado tiene así dimensiones $(T' \times F' \times 256)$.

Tras el submuestreo, se añaden ***embeddings* de posición espacial aprendibles** basados en características de Fourier (*learnable Fourier features*) [21]. Este *embedding* transforma un vector de coordenadas $\boldsymbol{x} \in \mathbb{R}^C$ en un vector de *embedding* $\boldsymbol{y} \in \mathbb{R}^E$ de acuerdo con:

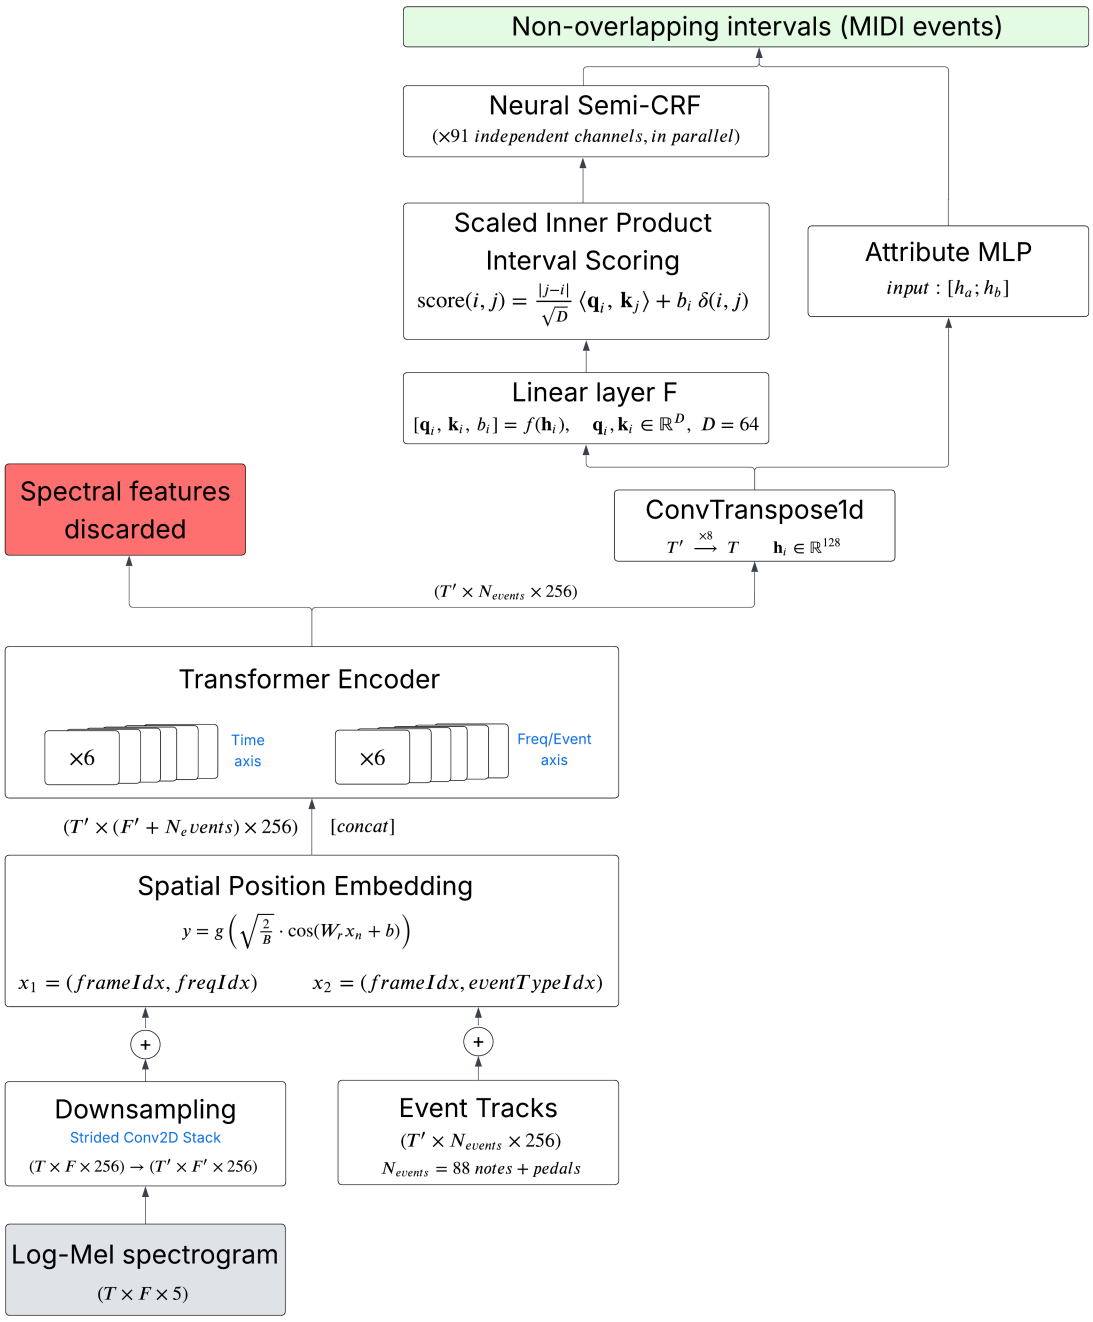


Figura 5.1: Esquema general de la arquitectura de Transkun. El espectrograma log-mel $(T \times F \times 5)$ se submuestrea mediante cuatro capas convolucionales *strided* hasta $(T' \times F' \times 256)$, al que se suma un *embedding* de posición espacial. Los *event tracks* $(T' \times N_{\text{events}} \times 256)$, inicializados también con *embedding* de posición (independiente), se concatenan a las representaciones del espectrograma y se procesan conjuntamente por el transformer encoder ($\times L$=6 capas). Tras el encoder, únicamente los *event tracks* se retienen y se remuestrean temporalmente mediante `ConvTranspose1d` hasta la resolución original T. Los *embeddings* $\mathbf{h}_i \in \mathbb{R}^{128}$ resultantes se usan en dos ramas paralelas: el módulo de *scoring* por producto interior escalado (que alimenta la capa semi-CRF para producir los intervalos no solapados) y el Attribute MLP (que predice velocidad, posiciones subframe e indicadores de segmento).

$$\boldsymbol{y} = g\left(\sqrt{\tfrac{2}{B}}\cos(\boldsymbol{W}_r\,\boldsymbol{x} + \boldsymbol{b})\right) \tag{5.2}$$

donde $\boldsymbol{W}_r \in \mathbb{R}^{B\times C}$ es una matriz aprendible inicializada desde $\mathcal{N}(0,\,\gamma^{-2})$; $\boldsymbol{b} \in \mathbb{R}^B$ es un sesgo aprendible inicializado desde $\mathcal{U}(-\pi,\,+\pi)$; B es la dimensión de las características de Fourier ($|B| = 256$); γ es un hiperparámetro de escala ($\gamma = 1$); y $g : \mathbb{R}^B \to \mathbb{R}^E$ es un perceptrón de dos capas con tamaño oculto 1024 [16]. Este *embedding* funciona como una red MLP que toma coordenadas espaciales como entrada, con la primera no linealidad siendo una función coseno escalada. Se elige por su sencillez y amplia compatibilidad con arquitecturas transformer.

El embedding se aplica de forma **independiente** a las representaciones del espectrograma submuestreado (con coordenadas $(\mathit{frameIdx}, \mathit{freqIdx})$) y a los *event tracks* (con coordenadas $(\mathit{frameIdx}, \mathit{eventTypeIdx})$). En ambos casos la operación es una **suma elemento a elemento** ($\oplus$) que enriquece las representaciones con información posicional sin modificar sus dimensiones.

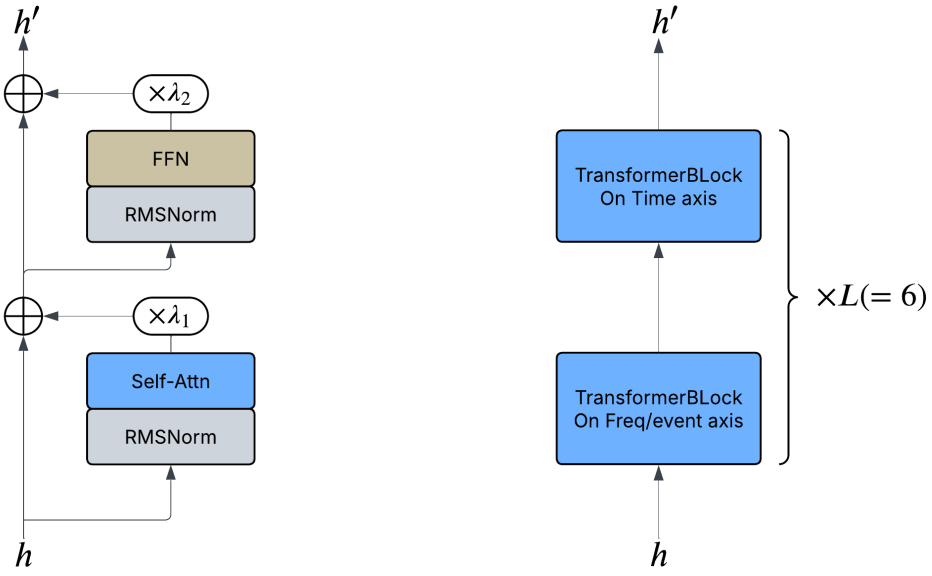
Para obtener las representaciones necesarias para el *scoring* de intervalos, Transkun introduce el concepto de ***event track***: un tensor de parámetros aprendibles de dimensiones $(T' \times N_{\text{events}} \times 256)$, donde $N_{\text{events}} = 91$ (88 notas más 3 pedales), que actúa como representación aprendible de cada tipo de evento a lo largo del tiempo en la resolución reducida. Esta idea es análoga a la de los tokens de detección (*detection tokens*) del modelo YOLOS [27], donde tokens aprendibles se añaden a las representaciones de imagen para que el transformer los especialice en tareas de predicción densa.

Los *event tracks* se inicializan sumándoles sus propios embeddings de posición espacial (Ecuación 5.2 con coordenadas $(\mathit{frameIdx}, \mathit{eventTypeIdx})$) y se **concatenan** al espectrograma submuestreado enriquecido a lo largo de la dimensión de secuencia [16]. El tensor resultante, de dimensiones $T' \times (F' + N_{\text{events}}) \times 256$, constituye la entrada al transformer encoder. Esta concatenación, indicada como `[concat]` en la Figura 5.1, permite que el transformer intercambie información entre las representaciones tiempo-frecuencia del audio y los *event tracks* a través del mecanismo de auto-atención, de forma completamente aprendible.

5.4 Transformer encoder no jerárquico

El *transformer encoder* es el componente central del sistema. Se trata de un ***encoder* no jerárquico** (sin submuestreo adicional ni estructura piramidal) compuesto por $L = 6$ capas, cuya elección como *backbone* responde a la coherencia entre su mecanismo de auto-atención y el módulo de *scoring* por producto interior que constituye la salida del sistema.

Cada una de las $L = 6$ capas del *encoder* contiene **dos bloques *transformer* en cascada**: uno que atiende a lo largo del **eje temporal** y otro a lo largo del **eje de frecuencia o tipo de evento**, alternando en cada capa [16]. Este esquema de **atención axial separable** reduce la complejidad computacional de $O(T^2(F' + N_{\text{events}})^2)$ a $O(T'^2 + (F' + N_{\text{events}})^2)$ por capa, y es análogo al empleado en otras arquitecturas *transformer* eficientes para datos multidimensionales [20, 23]. La organización de los bloques dentro de cada capa se ilustra en la Figura 5.2.



(a) `TransformerBlock` **(b)** Capa del encoder

Figura 5.2: Bloques constitutivos del transformer encoder. **(a)** Bloque transformer básico (`TransformerBlock`): aplica RMSNorm antes de la auto-atención y de la FFN, y escala la salida de cada subcapa mediante el factor aprendible λ (ReZero) antes de sumarlo al residual. **(b)** Organización de los bloques dentro de cada capa del encoder: un `TransformerBlock` atiende sobre el eje temporal y el siguiente sobre el eje de frecuencia o tipo de evento; esta configuración se repite $L = 6$ veces. Ilustración adaptada de [16].

Cada bloque transformer, ilustrado en la Figura 5.2, sigue el diseño estándar de *pre-normalización*: la entrada $\boldsymbol{h}$ se normaliza primero con **RMSNorm** [24], después se aplica la capa de auto-atención multi-cabeza (*Self-Attn*) o la red neuronal de avance (FFN, con tamaño de proyección interna 1024), y finalmente la salida de la subcapa se suma a la conexión residual. Para mejorar la estabilidad del entrenamiento de modelos profundos, se emplea **ReZero** [19]: un factor de escala aprendible λ_k ($k \in \{1, 2\}$), inicializado a 0,01, multiplica la salida de cada subcapa antes de sumarse al residual:

$$\boldsymbol{h}' = \boldsymbol{h} + \lambda_1 \cdot \text{Self-Attn}(\text{RMSNorm}(\boldsymbol{h})) \tag{5.3}$$

$$\boldsymbol{h}'' = \boldsymbol{h}' + \lambda_2 \cdot \text{FFN}(\text{RMSNorm}(\boldsymbol{h}')) \tag{5.4}$$

donde $\lambda_{1,0} = \lambda_{2,0} = 0{,}01$ son los valores de inicialización. Este mecanismo garantiza que, al inicio del entrenamiento, la salida de cada bloque sea casi idéntica a su entrada ($\boldsymbol{h}'' \approx \boldsymbol{h}$), lo que facilita el flujo del gradiente a través de las 12 subcapas del *encoder* (2 subcapas $\times$ 6 capas) y acelera la convergencia. El *encoder* utiliza **8 cabezas de atención** y una dimensión de embedding de 256 [16].

Tras el procesado por las $L = 6$ capas del *encoder*, únicamente se retienen los *event tracks* (descartando las representaciones del espectrograma, como indica el bloque rojo de la Figura 5.1) ya que son estos vectores los que contienen la información especializada por tipo de evento necesaria para el *scoring* de intervalos. Las representaciones del espectrograma, aunque participan en el proceso de atención cruzada durante el *encoder*, no se utilizan en las etapas posteriores.

Los *event tracks* extraídos tienen dimensiones $(T' \times N_{\text{events}} \times 256)$ en la resolución temporal reducida $T' = T/8$, y se pasan a la etapa de remuestreo.

5.5 Scoring por producto interior y semi-CRF

Tras el *encoder*, los *event tracks* se remuestrean temporalmente y se emplean para calcular la matriz de *scoring* que alimenta la capa semi-CRF. Esta sección describe estas dos últimas etapas del sistema: el remuestreo temporal y el módulo de *scoring* por producto interior escalado, el marco semi-CRF y su justificación teórica.

Dado que los *event tracks* operan en la resolución temporal reducida $T' = T/8$, es necesario recuperar la resolución original T para asignar puntuaciones a intervalos con precisión de trama. Para ello se aplica una única **capa convolucional transpuesta 1D** (`ConvTranspose1d`) con tamaño de kernel y *stride* igual a 8 y 128 canales de salida, sin activación no lineal. Esta capa realiza un remuestreo **lineal** a lo largo del eje temporal, produciendo *event tracks* de dimensiones $(T \times N_{\text{events}} \times 128)$. Cada vector $\boldsymbol{h}_i \in \mathbb{R}^{128}$ representa la información de un tipo de evento en la trama i en la resolución temporal completa.

La validez de este remuestreo lineal queda garantizada teóricamente por el Teorema 3.2 del artículo [16]: si la dimensión D' del espacio de baja resolución supera el producto $c \cdot |\mathcal{Y}|$, donde $c = 8$ es el factor de remuestreo y $|\mathcal{Y}|$ es el número de intervalos activos del tipo de evento, entonces el operador de remuestreo lineal no implica ninguna pérdida de expresividad. Con $D' = 256$ y $c = 8$, esto equivale a requerir $|\mathcal{Y}| < 32$ intervalos activos simultáneos por tipo de evento, condición que se satisface ampliamente en la práctica para el piano [16].

Para una secuencia de T tramas de audio, la transcripción se formula como la inferencia de un conjunto $\mathcal{Y}$ de intervalos cerrados no solapados $[i, j]$, donde i y j son índices de trama de inicio y fin respectivamente, y cada intervalo se asocia a un tipo de evento específico. El semi-CRF modela directamente esta estructura definiendo, para cada tipo de evento, dos tipos de puntuaciones a partir de la señal de audio $\mathcal{X}$ [15, 16]:

1. $\text{score}(i, j)$: una matriz triangular $T \times T$ que asigna una puntuación a cada intervalo candidato $[i, j]$, indicando en qué medida corresponde a un evento activo. Los valores diagonales $\text{score}(i, i)$ representan eventos de trama única.
2. $\text{score}_\epsilon(i-1, i)$: un vector de dimensión $T - 1$ que asigna una puntuación a cada par de tramas consecutivas $[i-1, i]$ no cubiertas por ningún intervalo en $\mathcal{Y}$, representando la inactividad del tipo de evento en ese instante.

La puntuación total de un conjunto de intervalos $\mathcal{Y}$ dada la entrada $\mathcal{X}$ se define como [16]:

$$\Phi(\mathcal{Y} \mid \mathcal{X}) = \sum_{[i,j] \in \mathcal{Y}} \text{score}(i, j) \; + \sum_{\substack{[i-1,i] \\ \text{no cubierto en } \mathcal{Y}}} \text{score}_\epsilon(i-1, i) \tag{5.5}$$

Para la **inferencia**, se utiliza la estimación del máximo a posteriori (MAP), que recupera el conjunto óptimo de intervalos no solapados mediante el algoritmo de Viterbi:

$$\mathcal{Y}^* = \arg\max_{\mathcal{Y}} \; \Phi(\mathcal{Y} \mid \mathcal{X}) \tag{5.6}$$

Para el **entrenamiento**, se emplea estimación de máxima verosimilitud (MLE), con la log-verosimilitud condicional:

$$\log p(\mathcal{Y} \mid \mathcal{X}) = \Phi(\mathcal{Y} \mid \mathcal{X}) - \log \sum_{\mathcal{Y}'} \exp \; \Phi(\mathcal{Y}' \mid \mathcal{X}) \tag{5.7}$$

donde la suma en el segundo término recorre todos los posibles conjuntos de intervalos no solapados. Este término de normalización, equivalente a la función de partición del modelo, se computa eficientemente mediante el algoritmo *forward-backward* [15]. Se instancia un semi-CRF independiente para cada tipo de evento, procesando en paralelo los 88 tipos de nota y los pedales, tal como indica la anotación $\times 91$ en la Figura 5.1.

El módulo de *scoring* calcula la matriz $\text{score}(i, j)$ a partir de los *event tracks* remuestreados. En el semi-CRF original [15], este módulo empleaba un MLP que tomaba como entrada los *embeddings* de los extremos del intervalo $\boldsymbol{h}_i$ y $\boldsymbol{h}_j$, su producto de Hadamard $\boldsymbol{h}_i \odot \boldsymbol{h}_j$ y los tres primeros momentos estadísticos sobre el intervalo:

$$\text{score}(i, j) = \text{MLP}([\boldsymbol{h}_i,\, \boldsymbol{h}_j,\, \boldsymbol{h}_i \odot \boldsymbol{h}_j,\, \boldsymbol{m}_1,\, \boldsymbol{m}_2,\, \boldsymbol{m}_3]) \tag{5.8}$$

Este enfoque es costoso en memoria: la matriz de *scoring* crece cuadráticamente con T, y la evaluación del MLP para cada par (i, j) requería procesamiento por segmentos y *gradient checkpointing* durante el entrenamiento, limitando la profundidad y anchura del módulo [16].

Transkun propone sustituirlo por una operación de **producto interior escalado** entre vectores de baja dimensión, tal como muestra la Figura 5.1:

$$\text{score}(i, j) = \frac{|j - i|}{\sqrt{D}} \langle \boldsymbol{q}_i,\, \boldsymbol{k}_j \rangle + b_i\, \delta(i, j) \tag{5.9}$$

donde $\delta(i, j)$ es la delta de Kronecker (vale 1 si $i = j$, 0 en caso contrario), y los vectores $\boldsymbol{q}_i \in \mathbb{R}^D$, $\boldsymbol{k}_i \in \mathbb{R}^D$ y el escalar $b_i \in \mathbb{R}$ se obtienen del *event track* $\boldsymbol{h}_i$ mediante una única capa lineal f, como indica el bloque *Linear layer F* de la Figura 5.1:

$$[\boldsymbol{q}_i,\, \boldsymbol{k}_i,\, b_i] = f(\boldsymbol{h}_i) \tag{5.10}$$

La matriz resultante tiene estructura de **rango bajo más diagonal**: el término del producto interior produce una matriz de rango $D = 64$, y el término $b_i\, \delta(i, j)$ añade la diagonal de forma independiente. Esta formulación es notablemente más simple que el MLP original y no requiere acceder a los *embeddings* internos del intervalo [16]. El factor $|j - i|/\sqrt{D}$ combina el escalado estándar $1/\sqrt{D}$ para estabilizar los gradientes (análogo al escalado del mecanismo de atención) con un factor proporcional a la longitud del intervalo $|j - i|$, que refleja que los intervalos más largos acumulan más evidencia acústica [16].

Justificación teórica de la expresividad

Una pregunta natural es si la simplicidad del producto interior implica una pérdida de capacidad expresiva respecto al MLP original. Yan y Duan responden a esta pregunta formalmente a través del siguiente resultado [16].

Se define una **matriz de *scoring* ideal** $\boldsymbol{S}_{\mathcal{Y}} \in \mathbb{R}^{T \times T}$ para un conjunto de intervalos $\mathcal{Y}$ como aquella en que:

$$\boldsymbol{S}_{\mathcal{Y}}(i, j) > 0 \quad \forall\, [i, j] \in \mathcal{Y}, \qquad \boldsymbol{S}_{\mathcal{Y}}(i, j) = -\epsilon \quad \text{en caso contrario}$$

con $\epsilon > 0$. Con esta matriz la decodificación MAP produce necesariamente $\mathcal{Y}$, ya que excluir cualquier intervalo activo o incluir cualquier intervalo inactivo reduciría la puntuación total.

Lema (Yan y Duan, 2024)**.** *El rango de una matriz de scoring ideal $\boldsymbol{S}_{\mathcal{Y}}$ para un conjunto de intervalos no solapados $\mathcal{Y}$ es $M+1$, donde $M = |\mathcal{Y}|$ es el número de intervalos activos.*

Teorema (Yan y Duan, 2024)**.** *Sea $\mathcal{Y}$ un conjunto de M intervalos no solapados sobre T pasos. Una matriz de scoring ideal $\boldsymbol{S}_{\mathcal{Y}}$ puede representarse como el producto interior por pares entre dos secuencias 1D $(\boldsymbol{k}_i)_i$ y $(\boldsymbol{q}_i)_i$ de vectores:*

$$\boldsymbol{S}_{\mathcal{Y}}(i,j) = \langle \boldsymbol{q}_i, \boldsymbol{k}_j \rangle$$

con $\operatorname{rank}(\boldsymbol{Q}_{\mathcal{Y}}) > M$ *y* $\operatorname{rank}(\boldsymbol{K}_{\mathcal{Y}}) > M$*, donde* $\boldsymbol{Q}_{\mathcal{Y}} = [\boldsymbol{q}_0, \ldots, \boldsymbol{q}_{T-1}]$ *y* $\boldsymbol{K}_{\mathcal{Y}} = [\boldsymbol{k}_0, \ldots, \boldsymbol{k}_{T-1}]$.

Este resultado tiene dos implicaciones prácticas directas [16]. En primer lugar, la dimensión D de los vectores $\boldsymbol{q}_i$ y $\boldsymbol{k}_i$ debe superar el número total de intervalos activos $|\mathcal{Y}|$. En segundo lugar, dado que los vectores se obtienen aplicando el remuestreo lineal u_c de la capa `ConvTranspose1d` sobre la secuencia de baja resolución, la dimensión requerida en el espacio de baja resolución satisface $D' > c \cdot |\mathcal{Y}|$ con $c = 8$. Con $D' = 256$, esto garantiza que el diseño de baja resolución temporal no implica ninguna pérdida de expresividad.

La relación entre la Ecuación 5.9 y el mecanismo de atención por producto interior escalado de los transformers [25] es clara: ambos computan una puntuación escalar para cada par de posiciones (i, j) mediante el producto interior entre un vector de consulta $\boldsymbol{q}_i$ y un vector de clave $\boldsymbol{k}_j$, escalado por $1/\sqrt{D}$. La diferencia estructural fundamental reside en la **normalización**: la atención normaliza por posición mediante *softmax*, produciendo una distribución de probabilidad local por fila, mientras que el semi-CRF normaliza de forma **global** sobre todos los posibles conjuntos de intervalos no solapados $\mathcal{Y}'$, garantizando que la decodificación sea globalmente óptima en lugar de localmente *greedy* [16].

Esta analogía no es solamente formal: motiva la elección del transformer como *backbone*, ya que puede interpretarse como una arquitectura que refina iterativamente las representaciones para que sean adecuadas para el *scoring* por producto interior. El estudio de ablación del artículo original confirma que una capa lineal para el cálculo de $\boldsymbol{q}$, $\boldsymbol{k}$ y b (Ecuación 5.10) supera a un MLP, alineándose con cómo se calculan las consultas y claves en los transformers estándar [16].

5.6 Predicción de atributos y procesado por segmentos

La capa semi-CRF produce, tras la decodificación MAP, un conjunto de intervalos $[i, j]$ para cada tipo de evento con precisión de trama. Sin embargo, la representación MIDI final requiere información adicional: la **velocidad** de cada nota, las **posiciones subframe** de inicio y fin para descuantizar los instantes exactos de onset y offset, y un par de **indicadores binarios** para gestionar correctamente los eventos que cruzan los límites entre segmentos de audio consecutivos. Estos atributos se predicen, en paralelo con la decodificación semi-CRF, mediante el Attribute MLP visible en la rama derecha de la Figura 5.1.

Una vez decodificados los intervalos, cada evento $[a, b]$ se caracteriza mediante cuatro atributos predichos por un **MLP de dos capas** con tamaño oculto de 512 unidades y *dropout* de tasa 0,1 [16]. La entrada al MLP es la concatenación de los *embeddings* del *event track* en los extremos del intervalo, $[\boldsymbol{h}_a^{\text{eventType}}; \boldsymbol{h}_b^{\text{eventType}}]$, tal como indica la anotación *input*: $[\mathbf{h}_a; \mathbf{h}_b]$ en la Figura 5.1:

- **Velocidad** (*velocity*) $\in \{0, \ldots, 127\}$: modelada como una distribución categórica sobre 128 clases mediante una capa *softmax*. La velocidad MIDI representa la intensidad de pulsación de cada tecla como un valor entero en el rango estándar MIDI [16].

- **Posiciones refinadas de onset y offset**: dado que los índices de trama a y b son posiciones cuantizadas (resolución de $\approx$ 23,2 ms), el instante exacto de inicio y fin de cada nota puede caer en cualquier punto dentro de esa trama. El modelo predice un desplazamiento relativo $\in (-0{,}5,\ 0{,}5)$ para cada extremo, modelado mediante una **distribución de Bernoulli continua** desplazada en $-0{,}5$ [26]. Esta distribución proporciona soporte continuo sobre el intervalo abierto $(-0{,}5,\ 0{,}5)$ con gradientes no nulos en todo el dominio [16].
- **Indicadores** `hasOnset` **y** `hasOffset` $\in \{0, 1\}$: dos variables binarias modeladas mediante distribuciones de Bernoulli, cuyo significado se detalla a continuación.

La pérdida de entrenamiento del módulo de predicción de atributos se suma a la log-verosimilitud del semi-CRF (Ecuación 5.7), de forma que el objetivo total es [16]:

$$\mathcal{L} = -\left[\log p(\mathcal{Y} \mid \mathcal{X}) + \sum_{e \in \mathcal{Y}} \log p(\text{atributos} \mid e)\right] \tag{5.11}$$

donde el segundo término se descompone en:

$$\begin{aligned} \log p(\text{atributos} \mid e) = \ & \log p(\text{velocity} \mid e) \\ & + \log p(\text{onset refinado} \mid e) \\ & + \log p(\text{offset refinado} \mid e) \end{aligned} \tag{5.12}$$

Procesado por segmentos y gestión de eventos incompletos

El transformer encoder opera sobre segmentos de audio de duración fija de **16 segundos**. Para transcribir grabaciones de mayor duración, el audio se divide en segmentos consecutivos con un **solapamiento del 50 %** (8 segundos de solape), y los eventos decodificados en cada segmento se ensamblan en una secuencia global [16].

El principal desafío de esta estrategia es la gestión de los eventos que **cruzan el límite** de un segmento. El semi-CRF original [15] descartaba directamente estos eventos durante el entrenamiento. Transkun adopta una solución más precisa: **truncar** el evento en el límite del segmento e introducir los indicadores binarios `hasOnset` y `hasOffset` para registrar si el truncamiento ha tenido lugar [16]:

- `hasOnset` $= 1$: el onset del evento pertenece al segmento actual (no ha sido truncado por el límite izquierdo).
- `hasOffset` $= 1$: el offset del evento pertenece al segmento actual (no ha sido truncado por el límite derecho).

Con estos indicadores, el algoritmo de ensamblado entre segmentos opera de la siguiente forma para cada tipo de evento [16]:

1. La decodificación dentro de cada segmento comienza desde el máximo entre: (a) el límite izquierdo del segmento actual, y (b) el offset del último evento en el conjunto resultado con `hasOffset` $= 1$.
2. Los eventos decodificados con `hasOnset` $= 1$ que no se solapan con el último evento del conjunto resultado se añaden directamente.

3. Para los eventos que se solapan con el último evento del conjunto resultado:
    - Si el nuevo evento tiene `hasOnset` $= 1$, reemplaza al anterior (el anterior era un fragmento truncado que ya no tiene soporte en el segmento nuevo).
    - Si el nuevo evento tiene `hasOnset` $= 0$, es la continuación del evento anterior, y ambos fragmentos se **fusionan** en un único evento.

Este mecanismo es especialmente relevante para los **pedales**, que con frecuencia superan los 16 segundos de duración de un segmento (en particular el pedal *sustain*), mientras que las notas individuales raramente exceden este límite. El estudio de ablación del artículo original confirma que omitir este tratamiento produce una degradación notable en las métricas de pedal, con un impacto prácticamente nulo en las métricas de notas [16].

5.7 Configuración del experimento

5.8 Preproceso y entrenamiento

5.9 Resultados

CAPÍTULO 6
Conclusiones

????? ????????????? ????????????? ????????????? ????????????? ?????????????

Bibliografía

[1] Valentin Emiya, Nancy Bertin, Bertrand David y Roland Badeau. MAPS - A piano database for multipitch estimation and automatic transcription of music. *INRIA Technical Report*, 2010.

[2] Francesco Foscarin, Katharina Hoedt, Gerhard Widmer y Maarten Grachten. Towards musically informed evaluation of piano transcription models. *arXiv preprint arXiv:2406.08454*, 2024.

[3] Google Magenta. The MAESTRO *dataset* v3.0.0. 2020.

[4] Yamaha Corporation. *Disklavier pianos.* Disponible en: https://usa.yamaha.com/products/musical_instruments/pianos/disklavier/index.html Consultado en: mayo de 2026.

[5] Curtis Hawthorne, Erich Elsen, Jialin Song, Adam Roberts, Ian Simon, Colin Raffel, Jesse Engel, Sageev Oore y Douglas Eck. Onsets and frames: Dual-objective piano transcription. *Proceedings of the International Society for Music Information Retrieval (ISMIR)*, pp. 50–57, 2018.

[6] Curtis Hawthorne, Andriy Stasyuk, Adam Roberts, Ian Simon, Cheng-Zhi Anna Huang, Sander Dieleman y Douglas Eck. Enabling factorized piano music modeling and generation with the MAESTRO *dataset*. *International Conference on Learning Representations (ICLR)*, 2019.

[7] Colin Raffel, Brian McFee, Eric J. Humphrey, Justin Salamon, Oriol Nieto, Dawen Liang y Daniel P. W. Ellis. mir_eval: A transparent implementation of common MIR metrics. *Proceedings of the 15th International Conference on Music Information Retrieval*, 2014.

[8] Qiuqiang Kong, Bochen Li, Xuchen Song, Yuan Wan y Yuxuan Wang. High-resolution piano transcription with pedals by regressing onset and offset times. *IEEE/ACM Transactions on Audio, Speech, and Language Processing*, vol. 29, pp. 3707–3717, 2021.

[9] Ethan Perez, Florian Strub, Harm de Vries, Vincent Dumoulin y Aaron Courville. FiLM: Visual reasoning with a general conditioning layer. *Proceedings of the AAAI Conference on Artificial Intelligence*, 2018.

[10] Qi Wang, Mingkuan Liu, Changchun Bao y Maoshen Jia. Harmonic-aware frequency and time attention for automatic piano transcription. *IEEE/ACM Transactions on Audio, Speech, and Language Processing*, vol. 32, pp. 2140–2152, 2024.

[11] Qi Wang, Mingkuan Liu y Maoshen Jia. Multitask frequency-time feature-wise linear modulation for piano transcription with pedal. *IEEE/ACM Transactions on Audio, Speech, and Language Processing*, vol. 33, pp. 1049–1062, 2025.

[12] C. Hawthorne, I. Simon, R. Swavely, E. Manilow y J. Engel. Sequence-to-sequence piano transcription with transformers. *Proceedings of the International Society for Music Information Retrieval (ISMIR)*, pp. 246–253, 2021.

[13] K. Toyama, T. Akama, Y. Ikemiya, Y. Takida, W.-H. Liao y Y. Mitsufuji. Automatic piano transcription with hierarchical frequency-time transformer. *Proceedings of the International Society for Music Information Retrieval (ISMIR)*, pp. 1–8, 2023.

[14] W. Wei, P. Li, Y. Yu y W. Li. HPPNet: Modeling the harmonic structure and pitch invariance in piano transcription. *Proceedings of the International Society for Music Information Retrieval (ISMIR)*, pp. 709–716, 2022.

[15] Y. Yan, F. Cwitkowitz y Z. Duan. Skipping the frame-level: Event-based piano transcription with neural semi-CRFs. *Proceedings of the Annual Conference on Neural Information Processing Systems (NeurIPS)*, vol. 25, pp. 20583–20595, 2021.

[16] Y. Yan y Z. Duan. Scoring time intervals using non-hierarchical transformer for automatic piano transcription. *Proceedings of the International Society for Music Information Retrieval (ISMIR)*, pp. 1–8, 2024.

[17] Alexey Dosovitskiy, Lucas Beyer, Alexander Kolesnikov, Dirk Weissenborn, Xiaohua Zhai, Thomas Unterthiner, Mostafa Dehghani, Matthias Minderer, Georg Heigold, Sylvain Gelly, Jakob Uszkoreit y Neil Houlsby. An image is worth 16x16 words: Transformers for image recognition at scale. *International Conference on Learning Representations (ICLR)*, 2021.

[18] Taegyun Kwon, Dasaem Jeong y Juhan Nam. Polyphonic piano transcription using autoregressive multi-state note model. *Proceedings of the International Society for Music Information Retrieval (ISMIR)*, pp. 454–461, 2020.

[19] T. Bachlechner, B. P. Majumder, H. Mao, G. Cottrell y J. McAuley. ReZero is all you need: Fast convergence at large depth. *Proceedings of the Thirty-Seventh Conference on Uncertainty in Artificial Intelligence (UAI)*, vol. 161, pp. 1352–1361, 2021.

[20] J. Ho, N. Kalchbrenner, D. Weissenborn y T. Salimans. Axial attention in multidimensional transformers. *arXiv preprint arXiv:1912.12180*, 2019.

[21] Y. Li, S. Si, G. Li, C.-J. Hsieh y S. Bengio. Learnable Fourier features for multi-dimensional spatial positional encoding. *Advances in Neural Information Processing Systems (NeurIPS)*, 2021.

[22] Y. Li, H. Mao, R. Girshick y K. He. Exploring plain vision transformer backbones for object detection. *European Conference on Computer Vision (ECCV)*, pp. 280–296, 2022.

[23] N.-C. Ristea, R. T. Ionescu y F. S. Khan. Septr: Separable transformer for audio spectrogram processing. *Proceedings of INTERSPEECH*, pp. 4103–4107, 2022.

[24] B. Zhang y R. Sennrich. Root mean square layer normalization. *Advances in Neural Information Processing Systems (NeurIPS)*, 2019.

[25] Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N. Gomez, Łukasz Kaiser e Illia Polosukhin. Attention is all you need. *Advances in Neural Information Processing Systems (NeurIPS)*, 2017.

[26] G. Loaiza-Ganem y J. P. Cunningham. The continuous Bernoulli: Fixing a pervasive error in variational autoencoders. *Advances in Neural Information Processing Systems (NeurIPS)*, 2019.

[27] Y. Fang, B. Liao, X. Wang, J. Fang, J. Qi, R. Wu, J. Niu y W. Liu. You only look at one sequence: Rethinking transformer in vision through object detection. *Advances in Neural Information Processing Systems (NeurIPS)*, 2021.

APÉNDICE A
Configuración del experimento MFT-FiLM

A.1 Entorno de ejecución y dependencias

El entrenamiento del modelo MFT-FiLM se llevó a cabo en el clúster de cómputo de alto rendimiento **tensor**, perteneciente al Departamento de Sistemas Informáticos y Computación (DSIC) de la Universidad Politécnica de Valencia. Este sistema está formado por un único nodo equipado con 503 **GB de memoria RAM** y cuatro unidades de procesamiento gráfico **NVIDIA L40S** con 48 GB de memoria GDDR6 ECC cada una. Las GPUs L40S pertenecen a la familia *Ada Lovelace*, orientadas a cargas de trabajo de inteligencia artificial en entornos de servidor. El hardware empleado en el artículo original consistía en dos tarjetas NVIDIA GeForce RTX 4090 de 24 GB de VRAM cada una [11]; la L40S cuenta individualmente con 48 GB, lo que permitió alojar el modelo con el tamaño de lote requerido sin restricciones de memoria.

El sistema de gestión de trabajos del clúster es **SLURM**, que organiza la ejecución mediante dos colas principales: `docencia`, para trabajos de duración inferior a 24 horas, y `long`, para trabajos de hasta 72 horas. Dada la duración estimada de entrenamiento reportada por los autores [11], fue necesario emplear la cola `long`.

El entorno software se configuró sobre Python 3.12 con `PyTorch` y `CUDA` compatibles con las GPUs L40S, y se instalaron las dependencias específicas del repositorio original (incluyendo `librosa`, `pretty_midi`, `mireval` y `joblib`) en un entorno virtual aislado para garantizar la reproducibilidad del experimento.

Durante la preparación del entorno surgieron dos incidencias relevantes. La primera fue un problema de **obsolescencia de dependencias**: para reproducir exactamente los espectrogramas CQT del trabajo original se requirió la versión **0.9.2** de `librosa`, pero esta versión dependía del módulo `pkg_resources`, eliminado en las versiones recientes de `setuptools` asociadas a Python 3.12. El problema se solventó manteniendo `librosa` 0.9.2 y degradando las herramientas de construcción del entorno a la última versión compatible, lo que permitió generar CQT idénticos a los descritos en [11] sin modificar el código original.

La segunda incidencia fue una **incompatibilidad de la API de PyTorch**. Los autores definieron la clase `CacheDataset` heredando de `TensorDataset` pero invocando al constructor padre sin tensores, algo que las versiones modernas de PyTorch (serie 2.x) rechazan con una excepción de desajuste dimensional. La solución consistió en sustituir la herencia de `TensorDataset` por la clase base estándar `torch.utils.data.Dataset`, manteniendo inalterada la lógica interna del conjunto de datos. Adicionalmente, fue necesario

regenerar los archivos de caché `.pth` tras algunos intentos fallidos de entrenamiento que habían corrompido parcialmente dichos ficheros.

A.2 Rendimiento del entrenamiento en el clúster

Durante el entrenamiento se observó un patrón de utilización de la GPU con oscilaciones periódicas de uso entre el 0 % y el 100 %, en lugar de un valor cercano al máximo continuado. Este fenómeno, conocido como *GPU starvation* o cuello de botella de entrada/salida (*I/O bottleneck*), se produce cuando la velocidad de cómputo de la GPU es significativamente superior a la velocidad con que la CPU puede preparar y transferir nuevos lotes de datos a la VRAM.

En la práctica, una vez que la GPU terminaba de procesar un lote de 10 espectrogramas (operación que, dada la compacidad del modelo, se completaba en pocos segundos), el proceso quedaba bloqueado a la espera de que la CPU leyera el siguiente lote desde los archivos `.pth` en disco y lo transfiriera a la VRAM a través del bus PCIe. Durante ese intervalo de espera la utilización de la GPU caía al 0 %. En la configuración empleada, este fenómeno fue particularmente pronunciado debido a que `tensor` sólo dispone de un nodo compartido por todos los usuarios, lo que impide reservar de forma dedicada todos los recursos de entrada/salida disponibles para un único `DataLoader`.

Como consecuencia directa de estas limitaciones de entrada/salida, la duración efectiva de cada época de entrenamiento fue de aproximadamente **83 minutos**, frente a los 43,5 minutos reportados por los autores originales con dos GPUs RTX 4090. En el *setup* original, la paralelización entre dos GPUs permitía solapar parcialmente la fase de transferencia de datos con el cómputo sobre la segunda tarjeta, mitigando significativamente este efecto y casi duplicando el rendimiento efectivo.

El clúster `tensor` impone una duración máxima de **72 horas** para los trabajos sometidos a la cola `long`. Dado que cada época requirió aproximadamente 83 minutos, el trabajo de entrenamiento fue interrumpido por SLURM al alcanzar dicho límite temporal, habiendo completado únicamente **30 de las 60 épocas planificadas**. A pesar de no haber completado el ciclo de entrenamiento descrito en el artículo original, el mecanismo de validación dinámica y guardado automático de *checkpoints* preservó el mejor modelo alcanzado durante las 30 épocas ejecutadas, que es el que se emplea en el análisis de resultados.

A.3 Parámetros de configuración del experimento

Una vez resueltos los problemas de compatibilidad, se ajustaron los hiperparámetros en el archivo central de configuración `constant_macro.py` para replicar las condiciones del artículo original. La Tabla A.1 resume los parámetros empleados [11].

Tabla A.1: Parámetros de configuración establecidos en `constant_macro.py` para el entrenamiento de MFT-FiLM.

Parámetro	Valor	Descripción
`EPOCH_RANGE`	60	Número total de épocas
`BATCH_SIZE`	10	Muestras por lote
`LEARNING_RATE`	0,0005	Tasa de aprendizaje
`DATASET_NAME`	`maestro-v3.0.0`	Versión del *dataset*
`DATASET_PATH`	ruta absoluta	Directorio raíz de los datos
`MODEL_PATH`	ruta absoluta	Directorio de salida del modelo
`MODEL_NAME`	`MTFiLM`	Identificador del modelo
`SCHEDULE_IDX`	`2x`	Objetivo: transcripción de notas

A.4 Herramientas de preprocesamiento de audio y MIDI

El preprocesamiento del conjunto MAESTRO se apoya en dos librerías ampliamente utilizadas en la comunidad de *Music Information Retrieval*: `librosa` para el tratamiento del audio y `pretty_midi` para el manejo de archivos MIDI.

La librería `librosa` es un paquete de Python orientado al análisis de señales de audio musicales. Entre otras funcionalidades, proporciona rutinas para el cálculo de representaciones tiempo–frecuencia como la Transformada de Fourier de tiempo corto (STFT) y la Transformada Q Constante (CQT), así como herramientas para el remuestreo, el filtrado y la extracción de descriptores espectrales. En este trabajo, `librosa` se utiliza para convertir cada grabación de MAESTRO en su correspondiente espectrograma CQT con los parámetros descritos en la Sección 4.2, que constituye la entrada del modelo MFT-FiLM.

Por otro lado, `pretty_midi` es una librería de Python diseñada para facilitar la lectura, escritura y manipulación estructurada de archivos MIDI. La librería ofrece una representación de alto nivel de las notas y de los eventos de control (por ejemplo, los pedales de *sustain* y *sostenuto*), lo que permite generar de forma directa los *piano rolls* de activación de nota a partir de una partitura MIDI. En el contexto de este proyecto, `pretty_midi` se utiliza para extraer las notas, extender su duración en función de los pedales y construir los mapas binarios de *ground truth* que se alinean temporalmente con los espectrogramas CQT preprocesados mediante `librosa`.

En conjunto, la combinación de `librosa` y `pretty_midi` permite establecer un flujo de preprocesamiento consistente entre el dominio del audio y el del MIDI, garantizando que las representaciones de entrada y las etiquetas de salida estén correctamente sincronizadas y sean comparables con las del trabajo original.