De señal acústica a partitura: transcripción automática de piano mediante aprendizaje profundo

Grado en Ingeniería Informática

Trabajo de Fin de Grado

Autor: Jorge Rodríguez González
Tutor: Alfons Juan Císcar



Escola Tècnica Superior d'Enginyeria **Informàtica**

etsinf

Índice

1. Introducción
2. Preliminares
3. MAESTRO
4. MFT-FiLM
5. Transkun
6. Evaluación en el *jazz*
7. Demo
8. Conclusiones



Introducción

Motivación

- Abundancia de audio
- Escasez de representaciones simbólicas

Objetivos

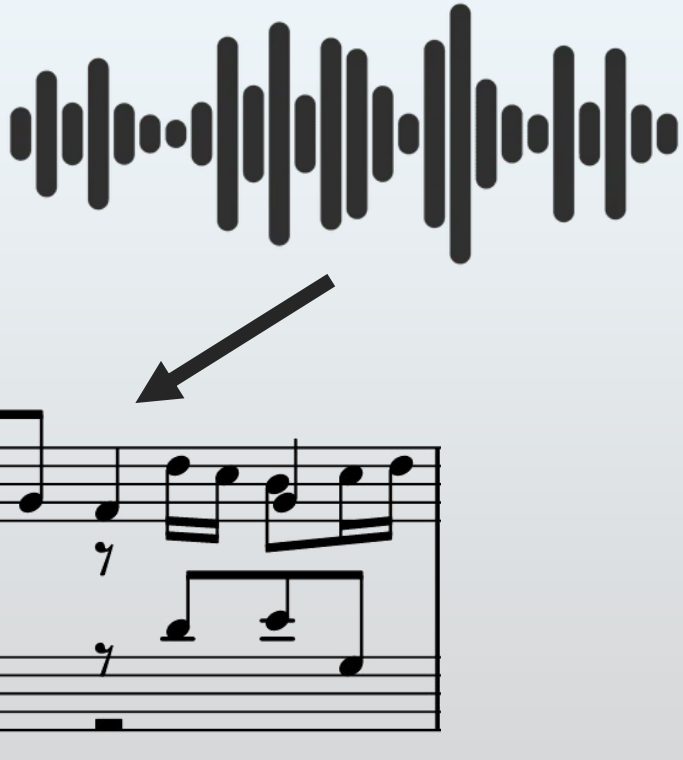
- MFT-FiLM | Transkun
- Estudiar, entrenar y evaluar en dominio clásico
- Evaluar capacidad de generalización: *jazz*

Preliminares

Aprendizaje automático

Aprendizaje profundo

- CNN
- Transformers



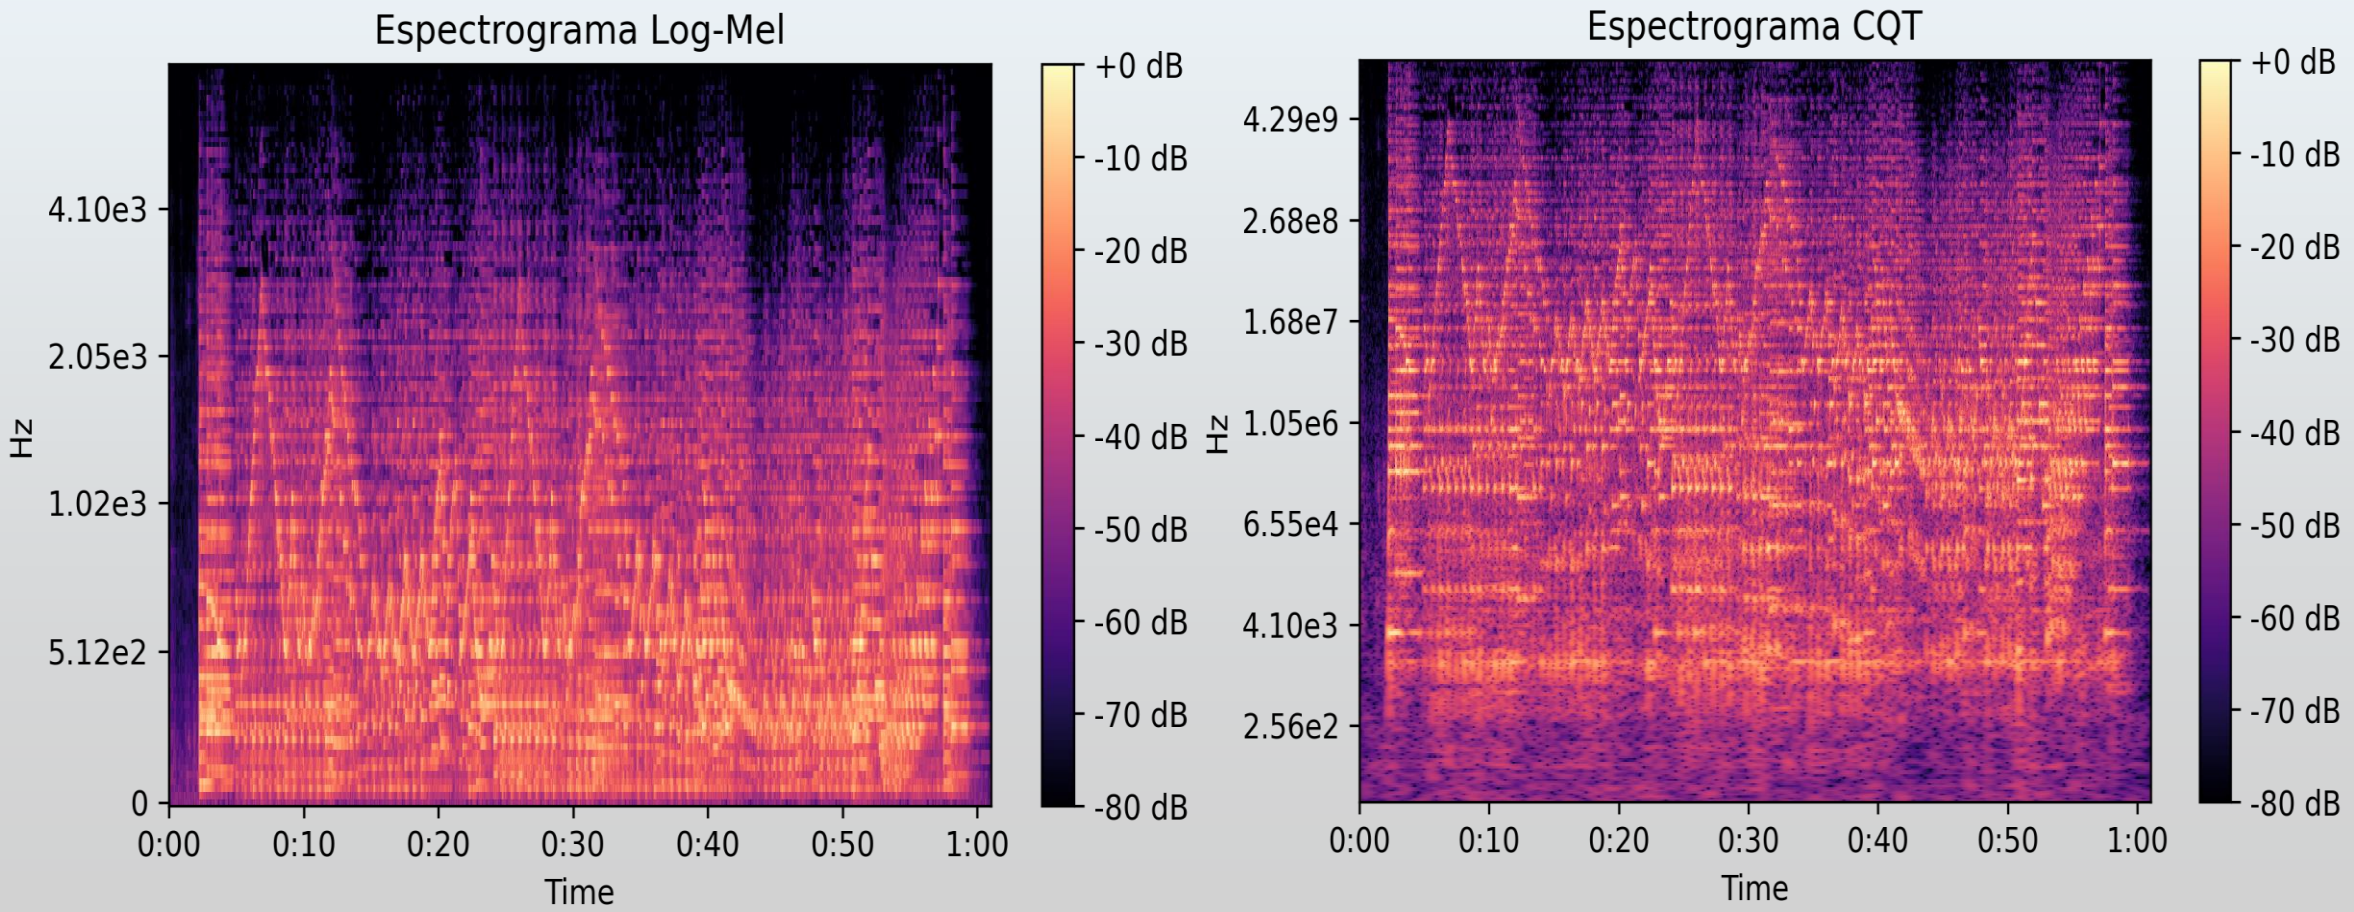
AMT Audio → partitura

Para piano

- Audio → *performance* MIDI → partitura

Preliminares

Representación del audio



Preliminares

Representación de la música

Performance MIDI

- Tiempos exactos
- Duraciones
- Velocidades

Partitura

- Figuras
- Voces
- Dinámicas



Preliminares

Representación de la música

MIDI2ScoreTransformer

- MIDI → MusicXML



MAESTRO

Piano acústico + MIDI alineado + referencia estándar

Origen: International Piano-e-Competition

Instrumento: Yamaha Disklavier

Características:

- 198,7 horas de audio
- 7,04 M de eventos MIDI
- Alineación de ≈ 3 ms



MAESTRO

Evaluación



Métricas: Precisión, *Recall* y F1

Nivel

- **Trama** → Notas activas
- **Nota**
  - ***Note Onset*** → Tono + Inicio
  - ***Note w/ Offset*** → Tono + Inicio + Fin
  - ***Note w/ Offset & Vel.*** → Tono + Inicio + Fin + Vel.

MAESTRO

Limitaciones



Sesgo de repertorio

→ Música clásica occidental

Sesgo de instrumento y grabación

→ Yamaha Disklavier

→ Mismo lugar y condiciones acústicas

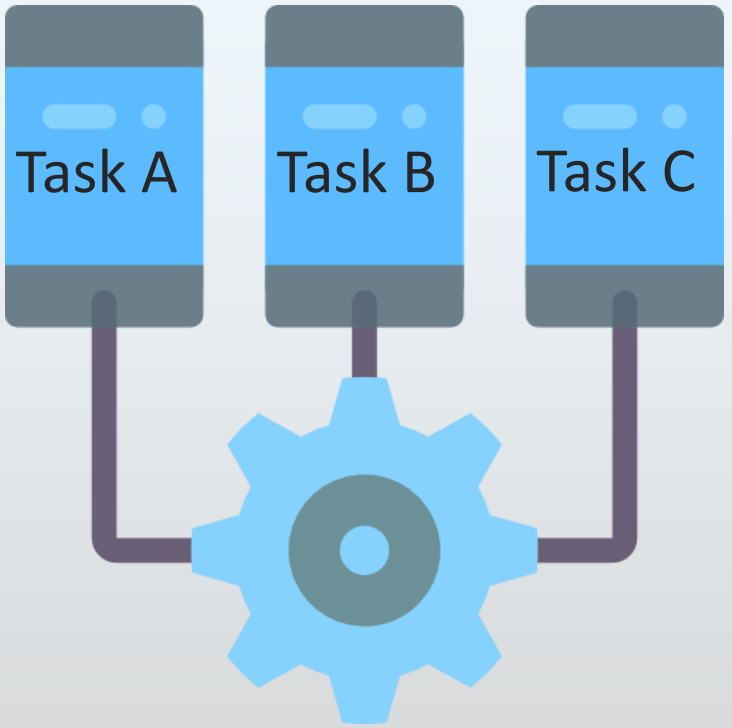
Ausencia de anotación de partitura

→ No permite transcripción *Audio-to-Score*

MFT-FiLM

Problema multitarea

- → *Onset*
- → *Offset*
- → *Frame*
- → *Velocity*



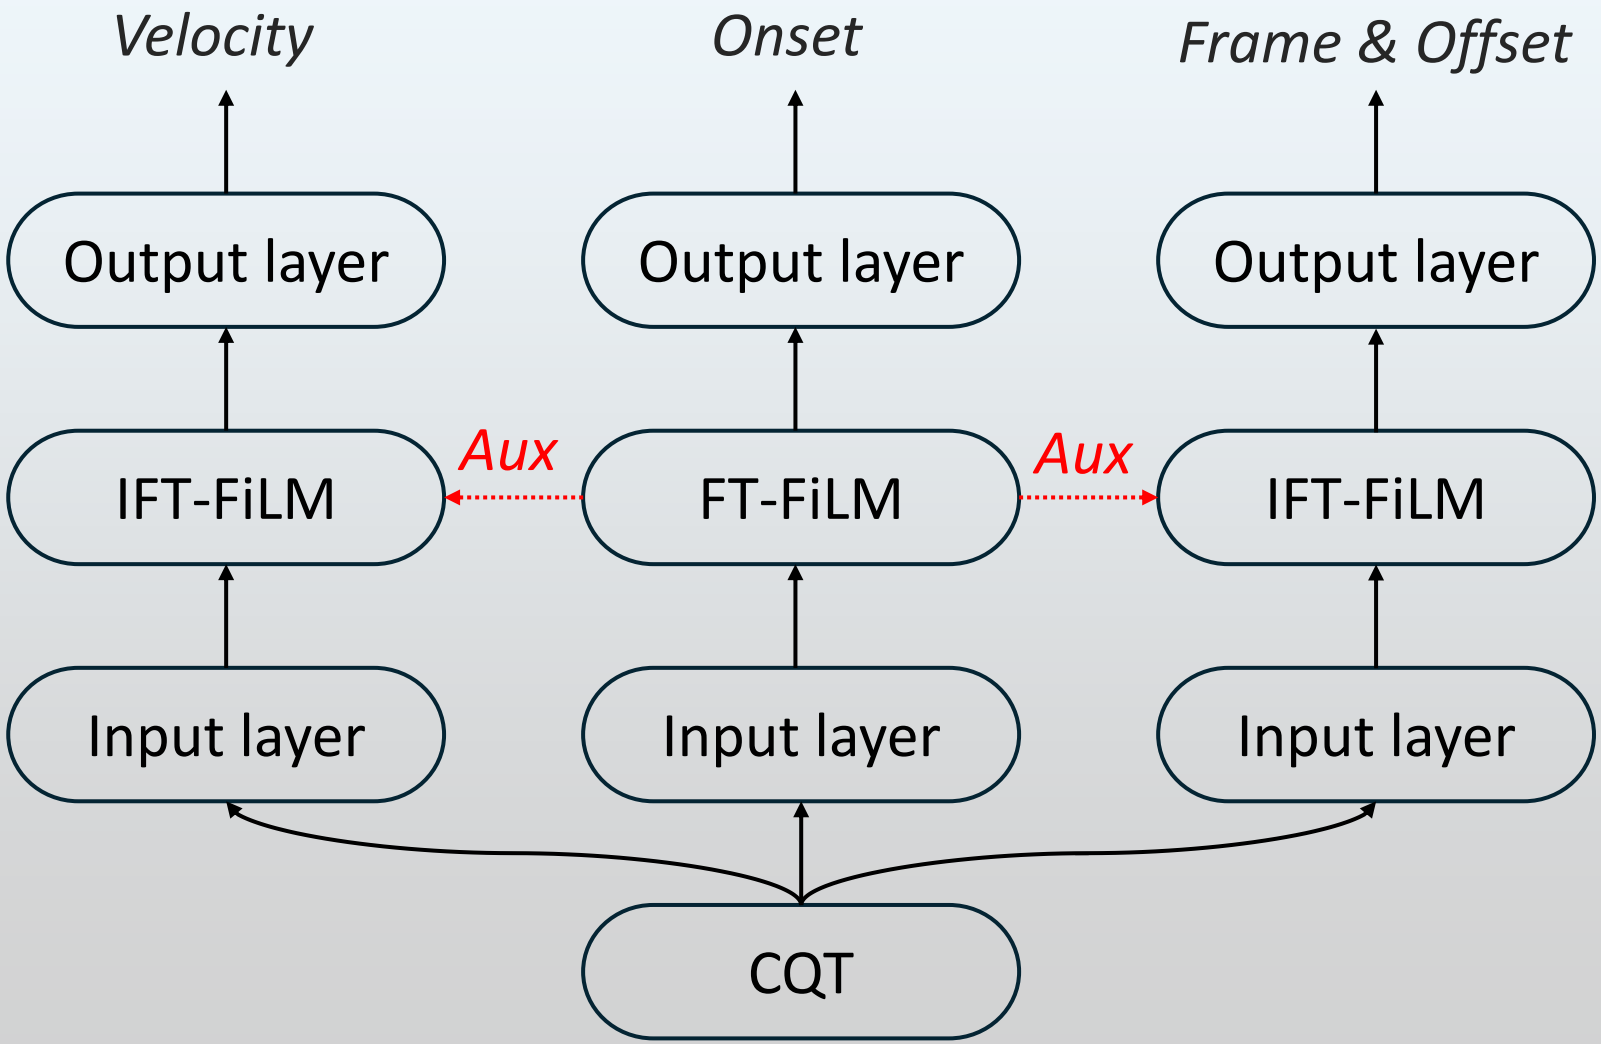
Modelo basado en módulos FiLM

1,2 M de parámetros

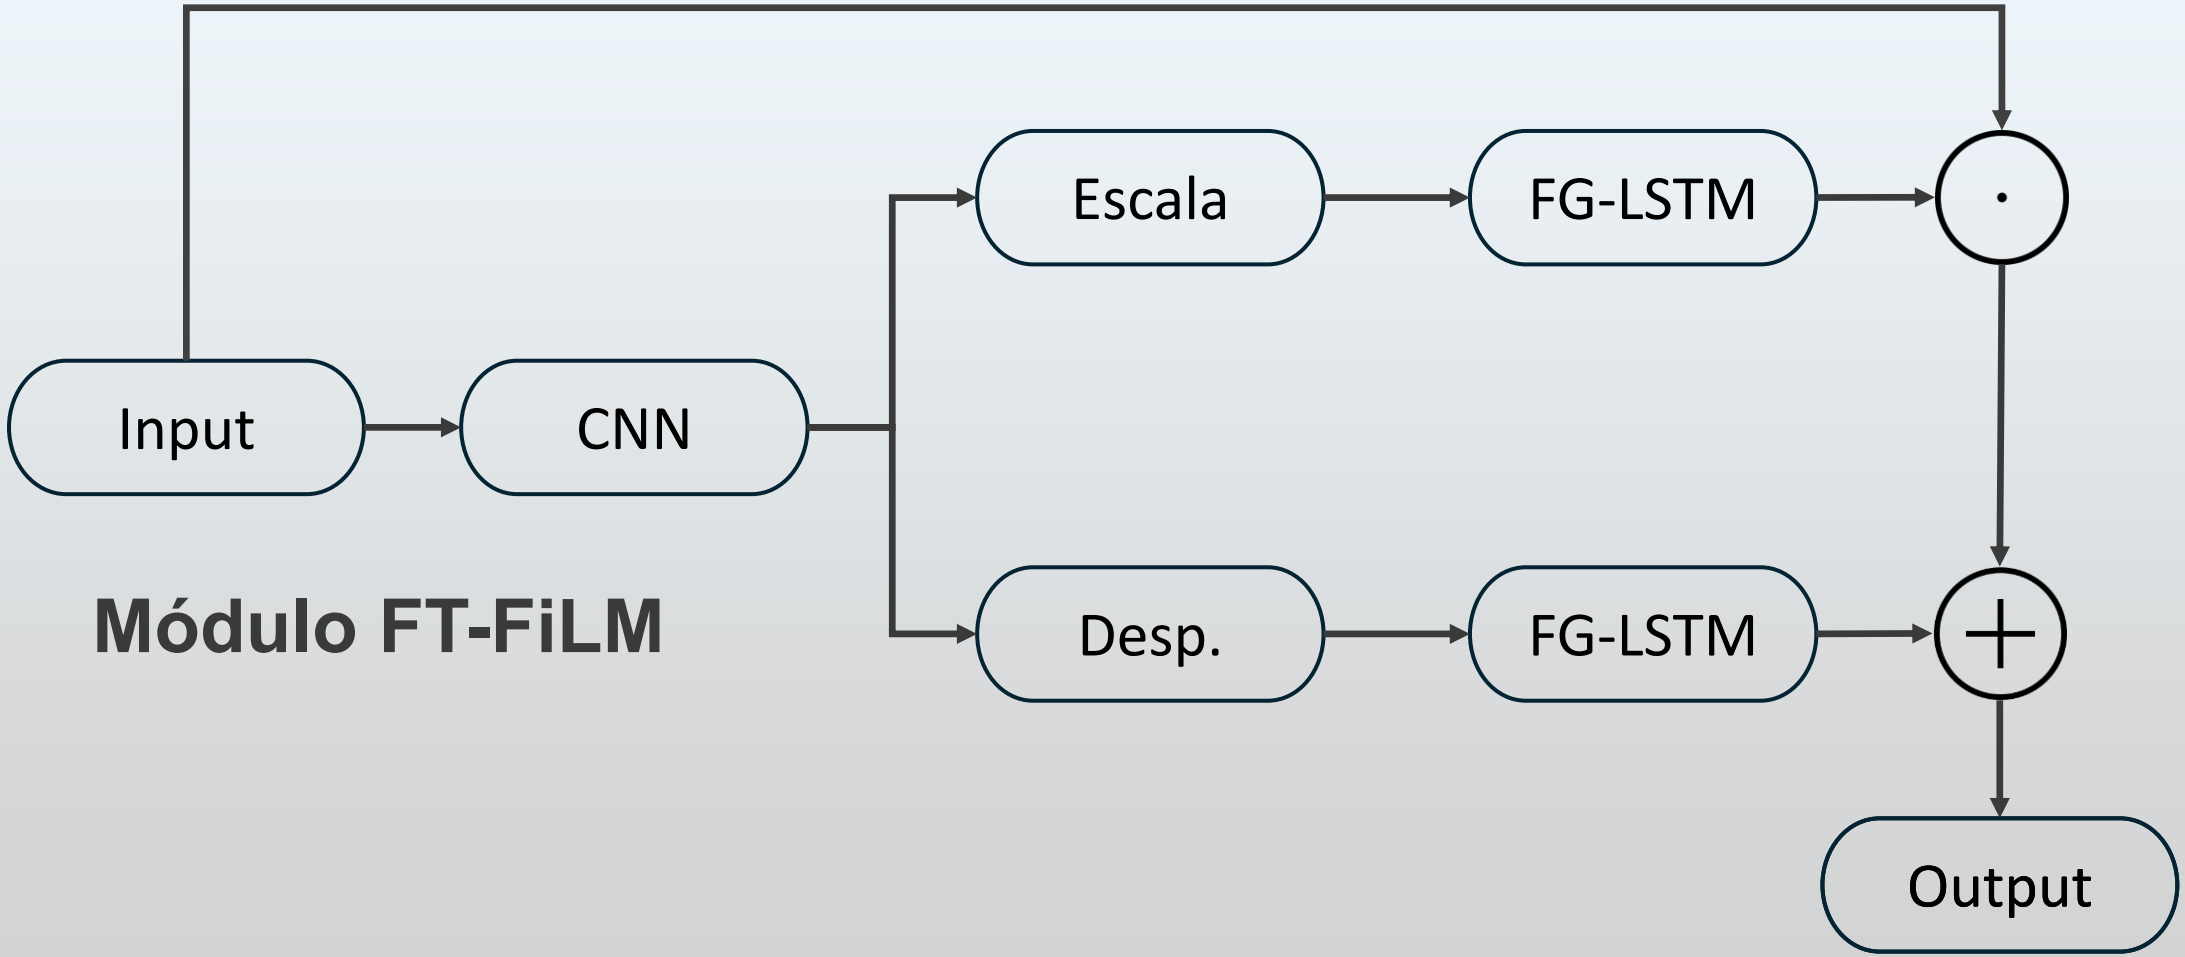
Arquitectura

Audio → CQT → red multitarea → algoritmo heurístico

MFT-FiLM

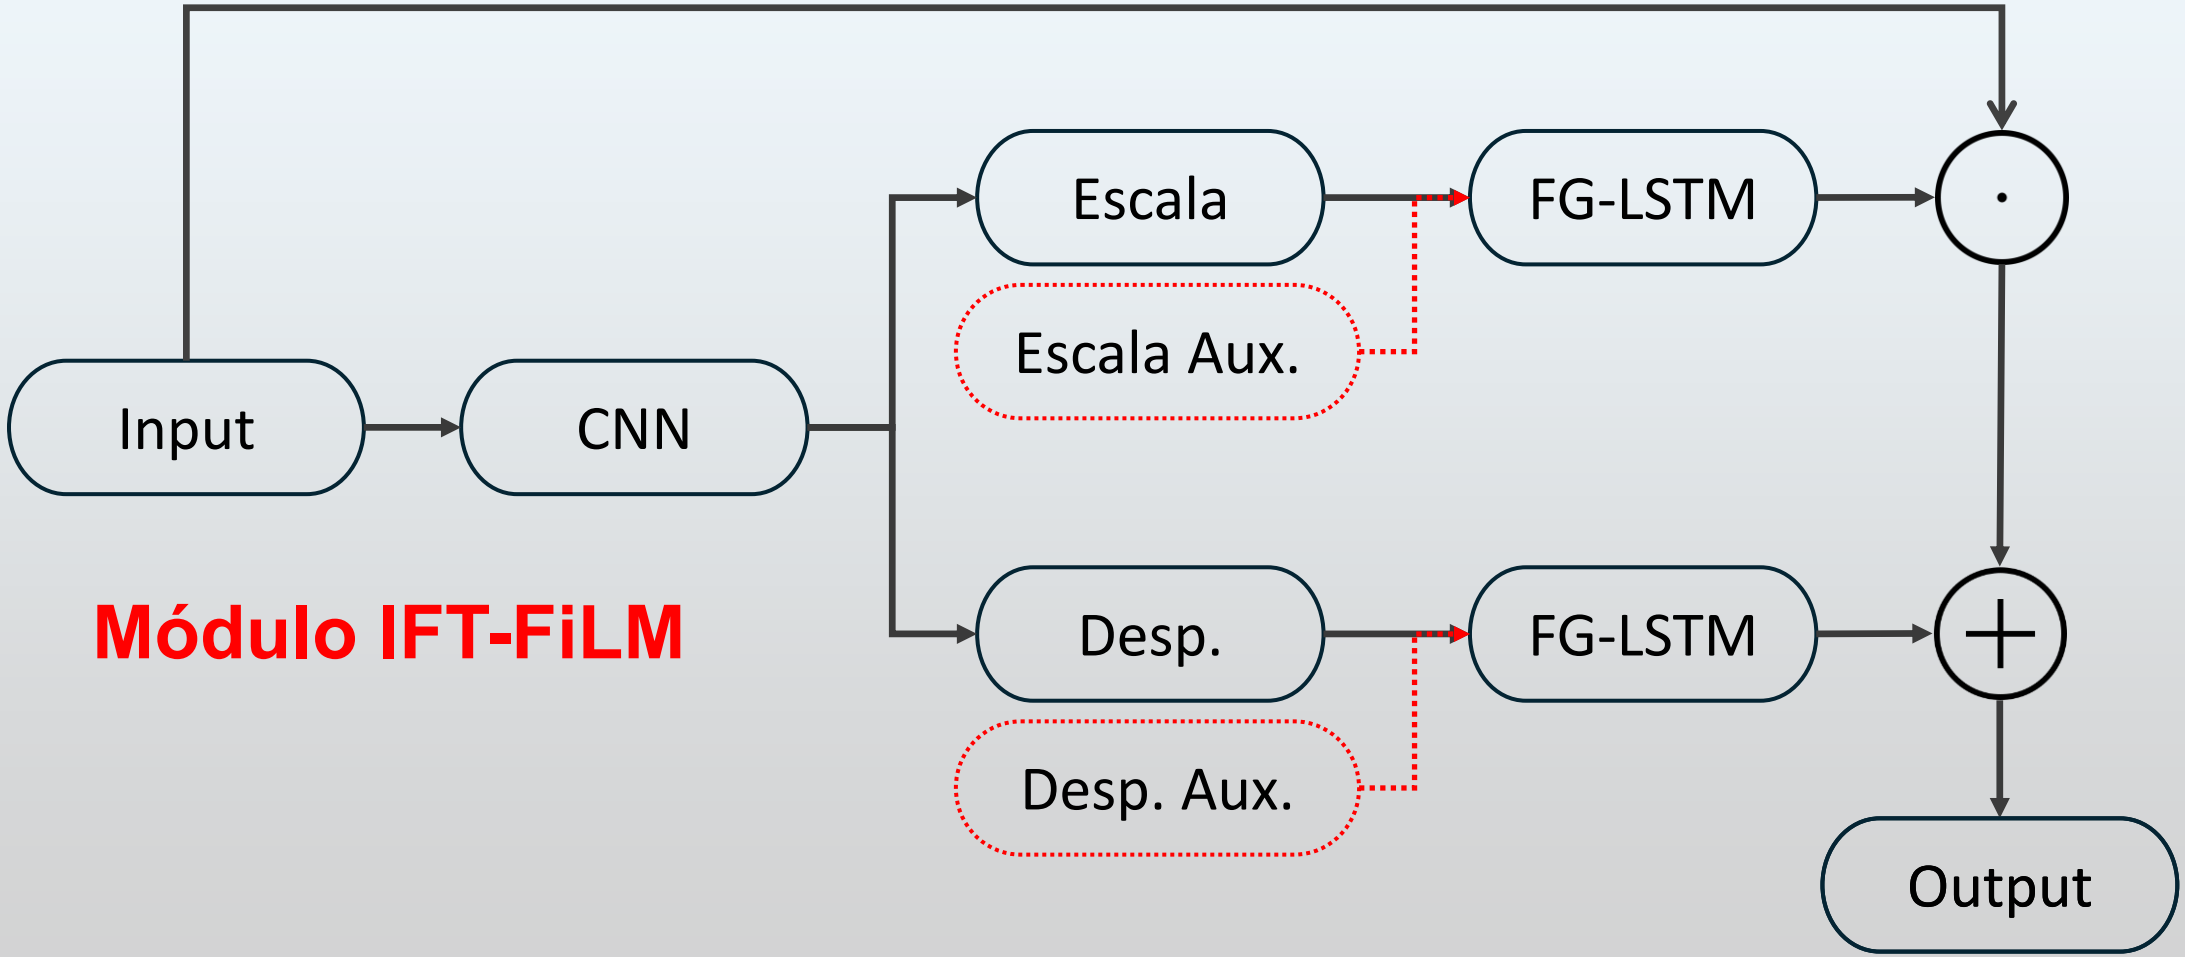

Velocity
Onset
Frame & Offset
Output layer
Output layer
Output layer
Aux
Aux
IFT-FiLM
FT-FiLM
IFT-FiLM
Input layer
Input layer
Input layer
CQT

MFT-FiLM



Módulo FT-FiLM

MFT-FiLM

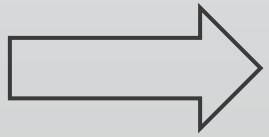


Módulo IFT-FiLM

MFT-FiLM

Modelo	Params.	Frame F1	On. F1	On.+Off. F1	On.+Off.+Vel. F1
Transformer	54 M	---	96,01	83,94	82,75
SemiCRF	9 M	90,75	96,11	88,42	87,44
HPPNet	1,2 M	93,15	97,18	83,80	82,24
hFT-Transformer	5,5 M	93,24	97,44	90,53	89,48
HATANet	6,4 M	94,04	97,81	90,57	89,25
SemiCRF V2	12,9 M	95,35	98,32	93,48	92,94
MFT-FiLM (autores)	1,2 M	94,75	98,39	92,46	91,79
MFT-FiLM (este trabajo)	**1,2 M**	**94,36**	**98,17**	**91,60**	**90,78**

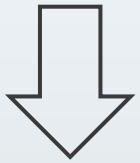
Métrica	P	R	P - R
Frame	95,27	93,56	1,71
On.	99,37	97,03	2,34
On.+Off.	92,70	90,54	2,16
On.+Off.+Vel.	91,86	89,73	2,13



Comportamiento conservador

Transkun

Skipping the Frame-Level





Notas como intervalos discretos

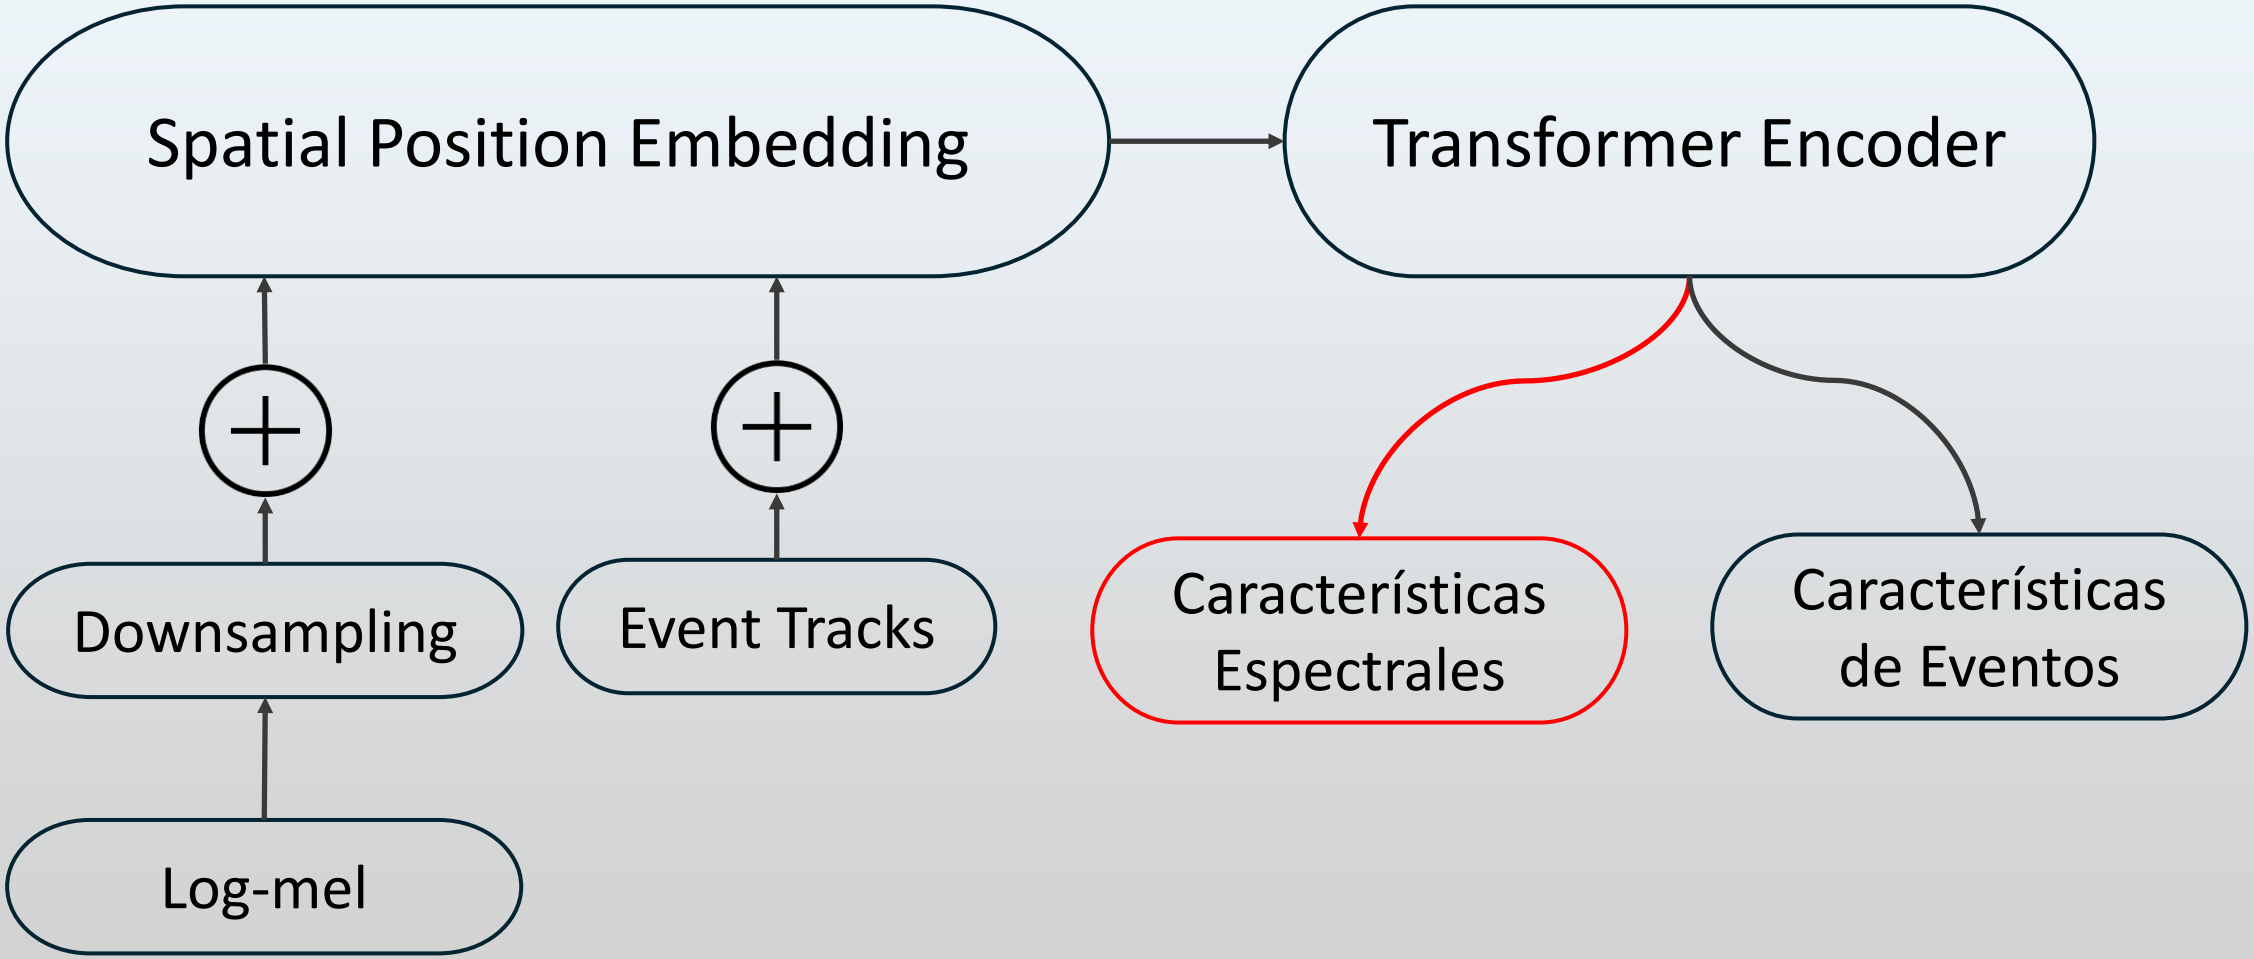
Inicio + duración + final

Puntuaciones para candidatos de eventos

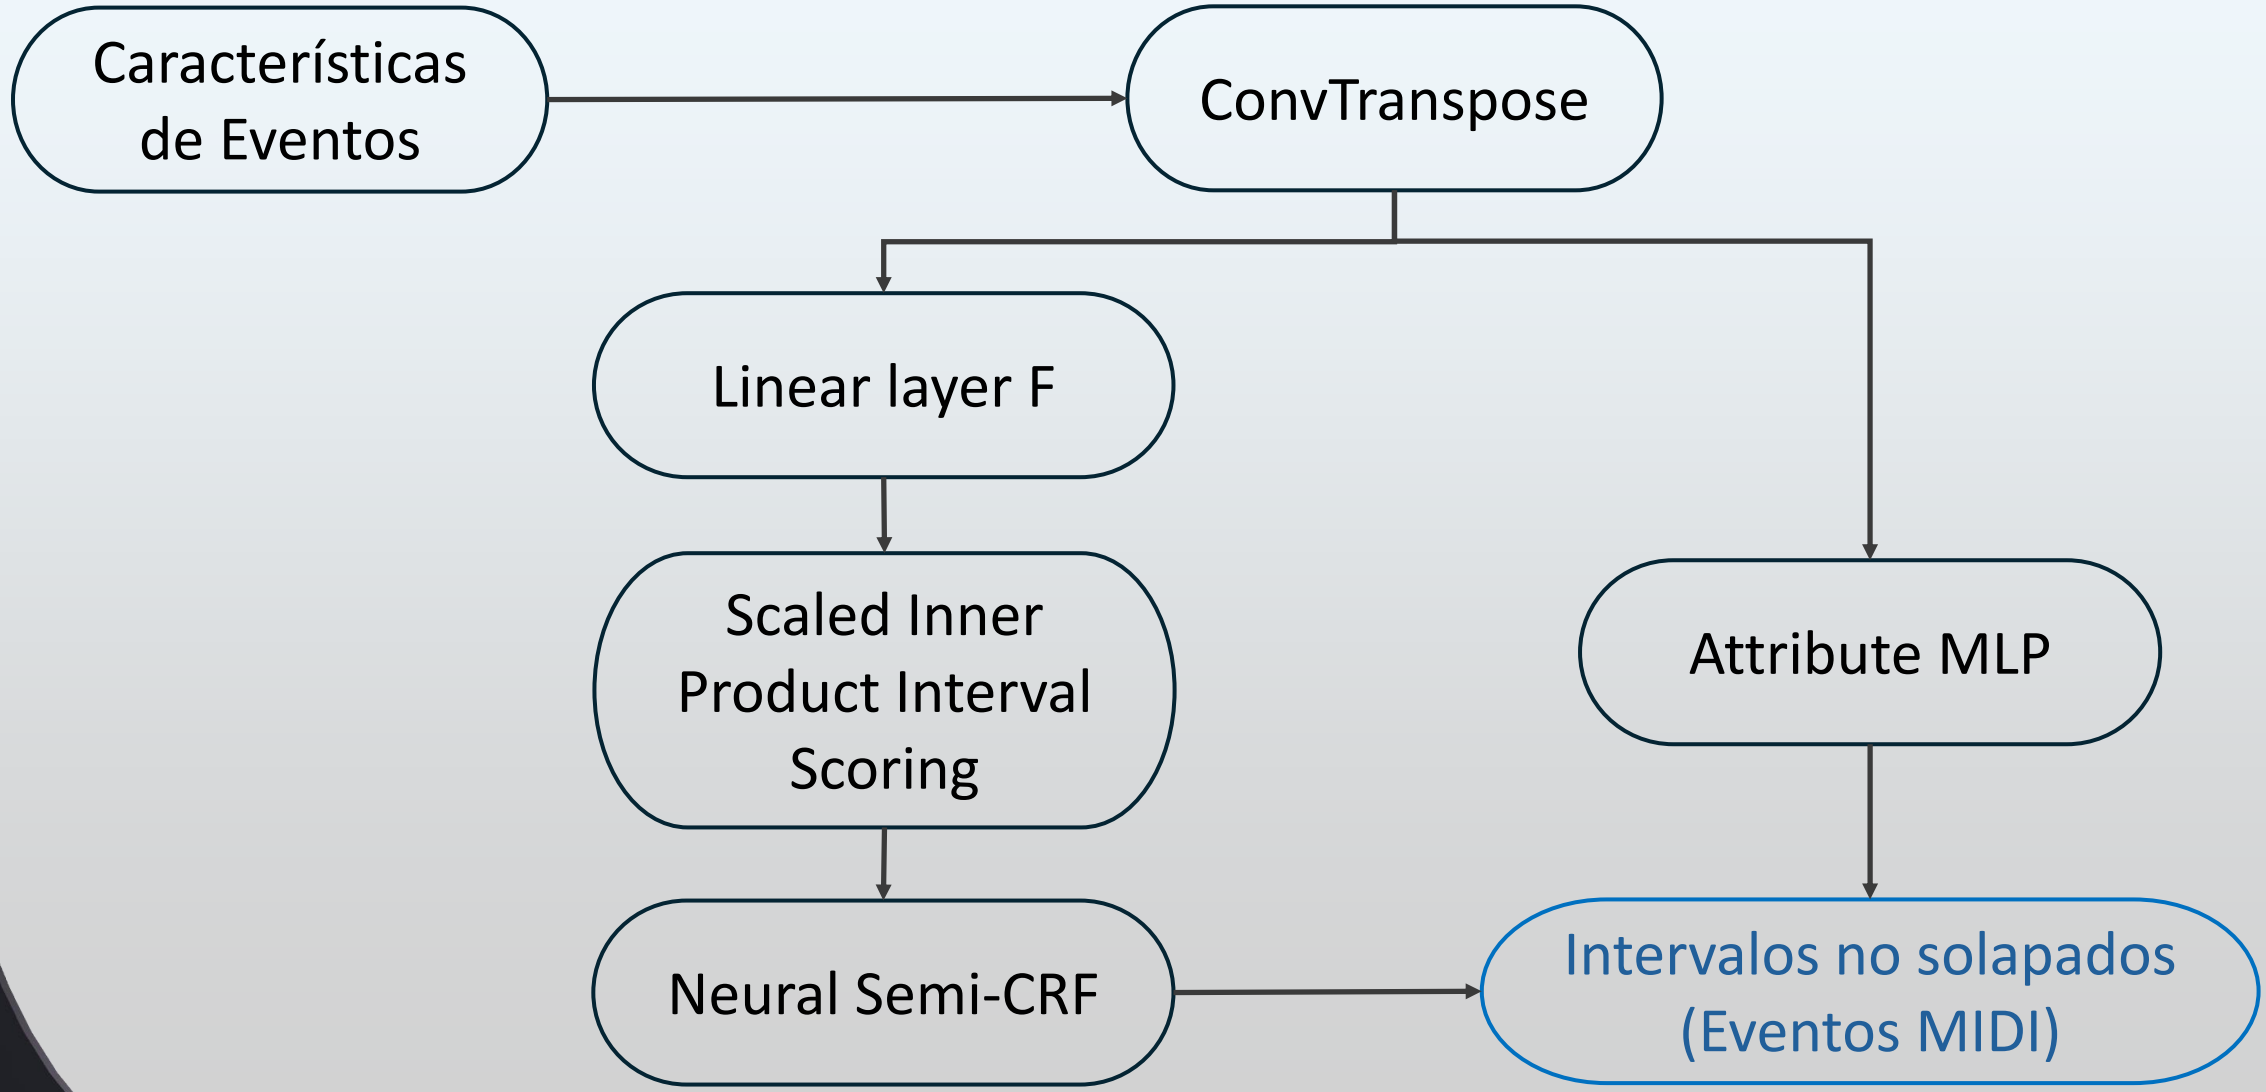
Arquitectura

Audio → log-mel → transformer → semi-CRF → eventos

Transkun


Spatial Position Embedding
Transformer Encoder
Downsampling
Event Tracks
Log-mel
Características Espectrales
Características de Eventos

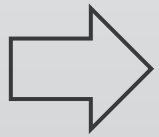
Transkun


Características de Eventos
ConvTranspose
Linear layer F
Scaled Inner Product Interval Scoring
Neural Semi-CRF
Attribute MLP
Intervalos no solapados (Eventos MIDI)

Transkun

Modelo	Params.	Frame F1	On. F1	On.+Off. F1	On.+Off.+Vel. F1
MFT-FiLM (autores)	1,2 M	94,75	98,39	92,46	91,79
MFT-FiLM (este trabajo)	**1,2 M**	**94,36**	**98,17**	**91,60**	**90,78**
Transkun (autores)	12,9 M	95,35	98,32	93,48	92,94
Transkun (este trabajo)	**12,9 M**	**94,69**	**98,03**	**92,06**	**91,52**

Métrica	P	R	P - R
Frame	95,21	94,69	0,52
On.	99,68	96,48	3,20
On.+Off.	93,58	90,62	2,96
On.+Off.+Vel.	93,03	90,10	2,93



Conservador en métricas de nota

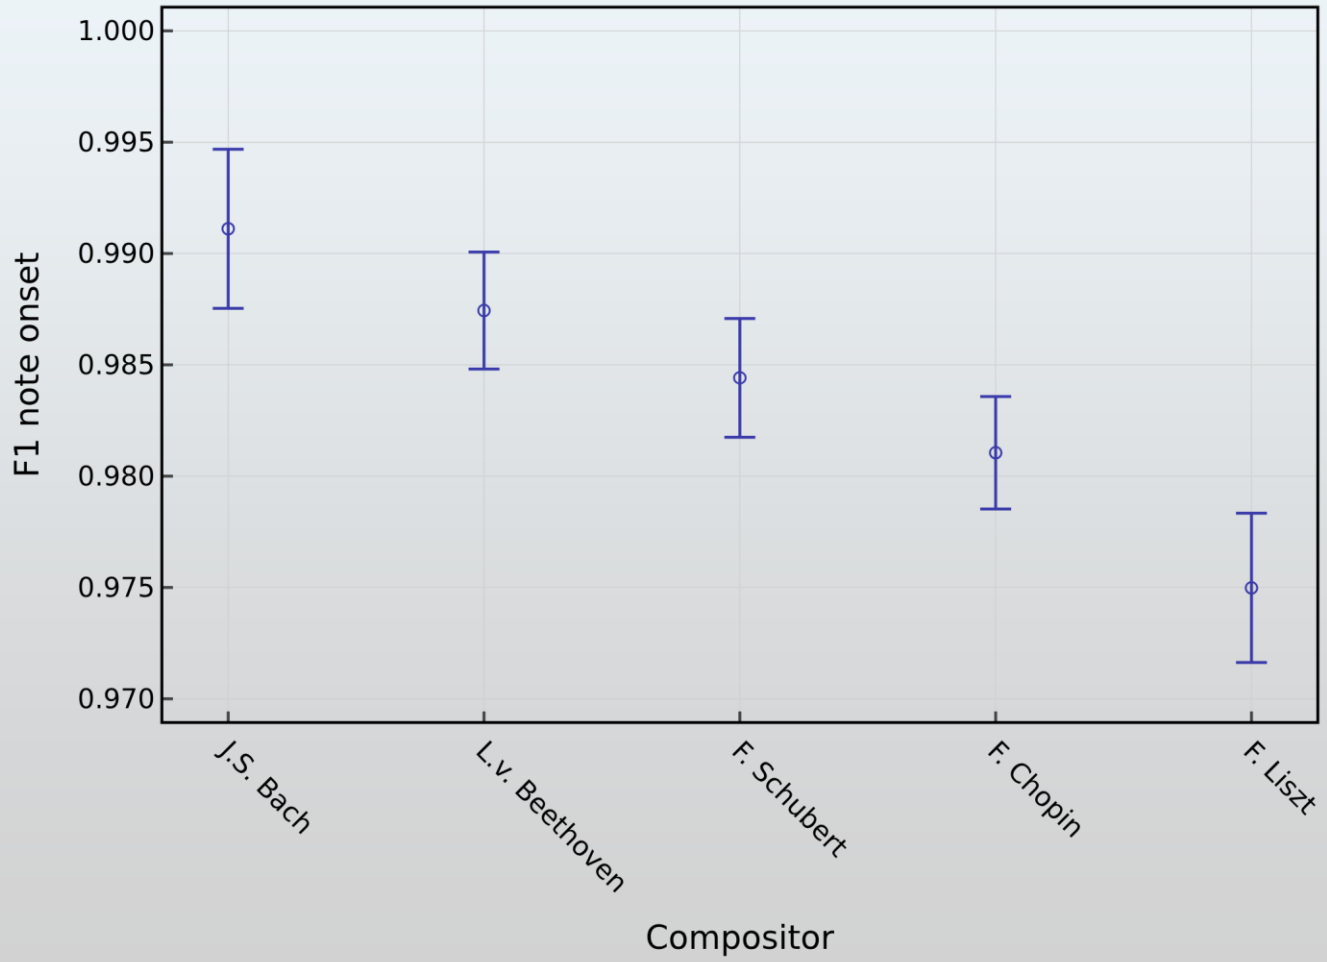
Análisis en MAESTRO

F1 note On.
- → Modelo
- → Duración
- → NPS
- → Polifonía máx.
- → Compositor

Modelo no significativo

Duración × NPS

Dificultad asociada al estilo



Jazz

Cambio estilístico

→ Síncopas
→ Disonancia
→ Pulso flexible/*swing*
→ Acordes densos
→ Silencios largos y abundantes

} **Lenguaje musical diferente**

PiJAMA: referencia en dominio de jazz

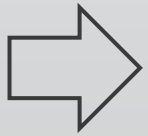
- Piano jazz solo
- Grabaciones reales
- Pseudo-etiquetas automáticas MIDI

Evaluación y resultados

Mismas métricas y umbrales que en MAESTRO

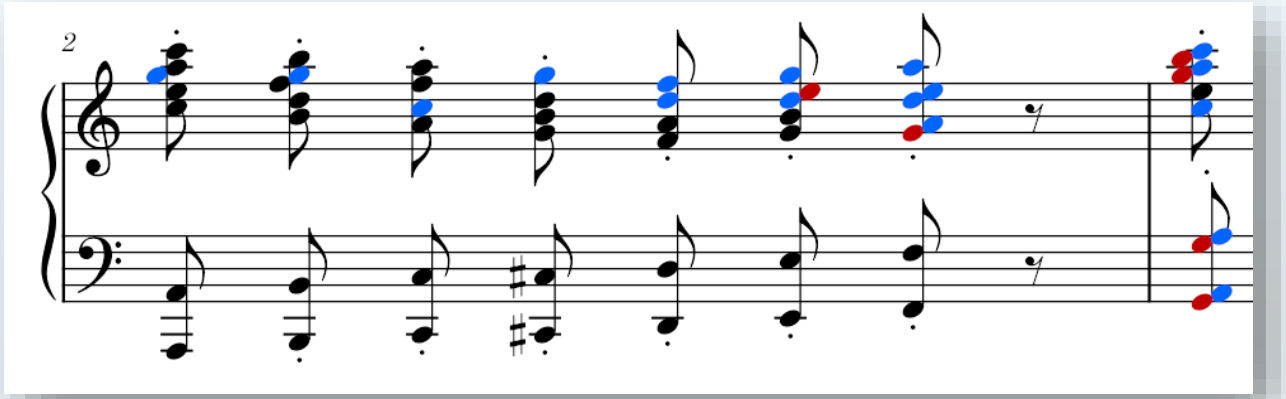
Dataset	Modelo	Frame F1	On. F1	On.+Off. F1	On.+Off.+Vel. F1
MAESTRO	Transkun	94,69	98,03	92,06	91,52
	MFT-FiLM	94,36	98,17	91,60	90,78
PiJAMA	Transkun	81,56	91,15	67,69	59,35
	MFT-FiLM	82,44	91,73	66,89	58,94

Modelo	Métrica	P	R	P - R
Transkun	Frame	79,62	84,13	-4,51
	On.	88,15	94,54	-6,39
	On.+Off.	65,48	70,17	-4,69
	On.+Off.+Vel.	57,42	61,51	-4,09
MFT-FiLM	Frame	82,67	83,29	-0,62
	On.	89,84	94,01	-4,17
	On.+Off.	65,44	68,54	-3,10
	On.+Off.+Vel.	57,68	60,37	-2,69



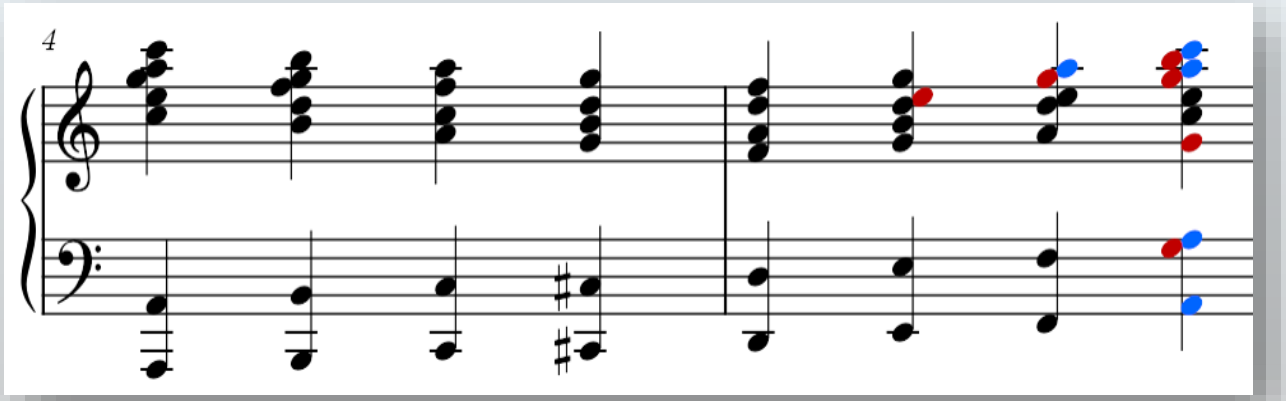
Comportamiento diferente

MFT-FiLM



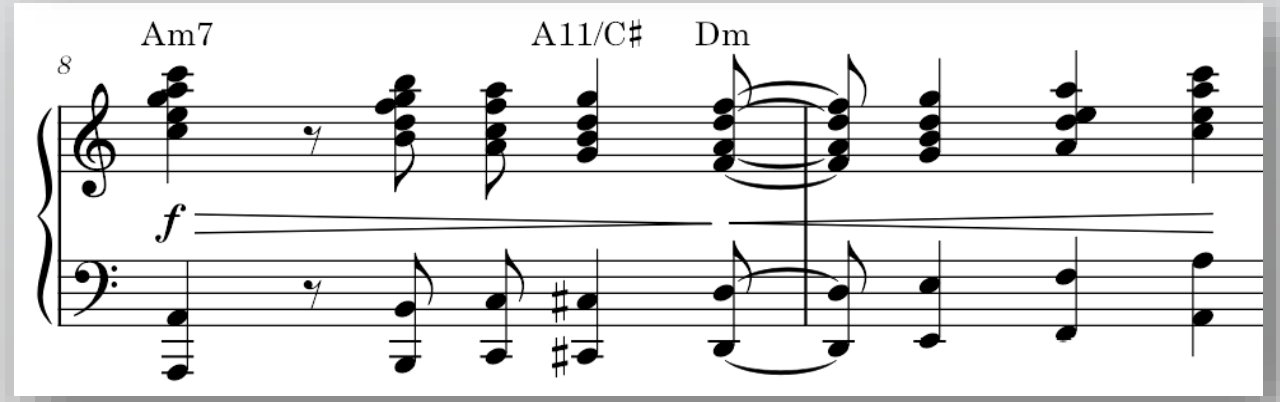
→ 17 omisiones
→ 6 fallos

Transkun



→ 5 omisiones
→ 6 fallos

Referencia



Conclusiones

- **Buen rendimiento de MFT-FiLM y Transkun sobre MAESTRO**
- **Diferencias significativas respecto a características musicales en dominio clásico**
- **Degradación clara en el jazz**
- **Transkun como mejor candidato en generalización jazz**

Trabajo futuro

- Obtención de datasets multigénero
- Fine-tuning a otros estilos
- Explorar modelos de mayor tamaño